TỔNG LIÊN ĐOÀN LAO DỘNG VIỆT NAM

TRƯỜNG ĐẠI HỌC TÔN ĐỨC THẮNG

KHOA CÔNG NGHỆ THÔNG TIN



Trần Văn Khang – 52400199

Trần Tấn Lực – 52400055

Ngô Đức Huân – 52400192

BÁO CÁO CUỐI KÌ

Môn học: Khai thác dữ liệu và Khai phá tri thức.

DỰ ÁN:

CUSTOMER ANALYTICS FOR E−COMMERCE.

THÀNH PHỐ HỒ CHÍ MINH, NĂM 2026

TỔNG LIÊN ĐOÀN LAO ĐỘNG VIỆT NAM

TRƯỜNG ĐẠI HỌC TÔN ĐỨC THẮNG

KHOA CÔNG NGHỆ THÔNG TIN



Trần Văn Khang – 52400199

Trần Tấn Lực – 52400055

Ngô Đức Huân – 52400192

BÁO CÁO CUỐI KÌ

Môn học: Khai thác dữ liệu và Khai phá tri thức.

DỰ ÁN:

CUSTOMER ANALYTICS FOR E−COMMERCE.

Người hướng dẫn

ThS. Hoàng Anh

THÀNH PHỐ HỒ CHÍ MINH, NĂM 2026

LỜI CẢM ƠN

Chúng em xin chân thành cảm ơn thầy đã tận tình, quan tâm giảng dạy trong suốt quá trình học và hướng dẫn chúng em hoàn thành bài báo cáo này. Nếu không có những nỗ lực hoàn thiện bài giảng cũng như chỉ dẫn đầy tâm huyết của thầy thì bài báo cáo này khó hoản thiện được.

Tuy nhiên, kiến thức về môn học của chúng em vẫn còn những hạn chế và thiếu sót nhất định. Do đó, không tránh khỏi những thiếu sót trong quá trình hoàn thành bài tiểu luận này. Mong thầy xem và góp ý để bài tiểu luận của em hoàn thiện hơn.

Một lần nữa, em xin cảm ơn thầy vì đã trợ giúp chúng em hoàn thành bài tiểu luận của mình. Sự giúp đỡ và động viên của thầy là một niềm động lực to lớn đối với chúng em, và chúng em hy vọng sẽ tiếp tục được học hỏi và phát triển dưới sự hướng dẫn của thầy trong tương lai.

Em xin chân thành cảm ơn!

TP.Hồ Chí Minh, ngày 20 tháng 10 năm 2026

Tác giả

(Ký tên và ghi rõ họ tên)

Khang	***Lực***	***Huân***
Trần Văn Khang	***Trần Tấn Lực***	***Ngô Đức Huân***

CÔNG TRÌNH ĐƯỢC HOÀN THÀNH
TẠI TRƯỜNG ĐẠI HỌC TÔN ĐỨC THẮNG

Chúng tôi xin cam đoan đây là công trình nghiên cứu của riêng chúng tôi và được sự hướng dẫn khoa học của *ThS. Hoàng Anh*. Các nội dung nghiên cứu, kết quả trong đề tài này là trung thực và chưa công bố dưới bất kỳ hình thức nào trước đây. Những số liệu trong các bảng biểu phục vụ cho việc phân tích, nhận xét, đánh giá được chính tác giả thu thập từ các nguồn khác nhau có ghi rõ trong phần tài liệu tham khảo.

Ngoài ra, trong dự án còn sử dụng một số nhận xét, đánh giá cũng như số liệu của các tác giả khác, cơ quan tổ chức khác đều có trích dẫn và chú thích nguồn gốc.

Nếu phát hiện có bất kỳ sự gian lận nào chúng tôi xin hoàn toàn chịu trách nhiệm về nội dung dự án của mình. Trường Đại học Tôn Đức Thắng không liên quan đến những vi phạm tác quyền, bản quyền do tôi gây ra trong quá trình thực hiện (nếu có).

TP.Hồ Chí Minh, ngày 20 tháng 10 năm 2026

Tác giả

(Ký tên và ghi rõ họ tên)

Khang	***Lực***	***Huân***
Trần Văn Khang	***Trần Tấn Lực***	***Ngô Đức Huân***

PHẦN XÁC NHẬN VÀ ĐÁNH GIÁ CỦA GIẢNG VIÊN

Phần xác nhận của GV hướng dẫn

_____

_____

_____

_____

TP.Hồ Chí Minh, ngày ... tháng ... năm ....

Tác giả

(Ký tên và ghi rõ họ tên)

Phần đánh giá của GV chấm bài

_____

_____

_____

_____

TP.Hồ Chí Minh, ngày ... tháng ... năm ....

Tác giả

(Ký tên và ghi rõ họ tên)

MỤC LỤC

LỜI CẢM ƠN....3
PHẦN XÁC NHẬN VÀ ĐÁNH GIÁ CỦA GIẢNG VIÊN....5
MỤC LỤC....6
CHƯƠNG 1: GIỚI THIỆU VÀ MỤC TIÊU BÀI TOÁN....8
1.1. Bối cảnh bài toán....8
1.2. Từ mục tiêu nghiệp vụ đến mục tiêu khai phá dữ liệu....8
1.3. Phạm vi, giả định và tiêu chí thành công....9
1.4. Quy trình CRISP-DM và kiến trúc dự án....10
CHƯƠNG 2: HIỂU DỮ LIỆU (DATA UNDERSTANDING)....11
2.1. Nguồn dữ liệu và cấu trúc dữ liệu....11
2.2. Chất lượng dữ liệu....11
2.3. Phân bố theo quốc gia và thời gian....13
2.4. Ngoại lai và quyết định xử lý....14
2.5. Tóm tắt phát hiện và hệ quả thiết kế....15
CHƯƠNG 3: CHUẨN BỊ DỮ LIỆU (DATA PREPARATION)....16
3.1. Làm sạch dữ liệu theo năm bước....16
3.2. Dữ liệu sau làm sạch và xử lý giá trị thiếu....17
3.3. Tạo đặc trưng RFM và đặc trưng Churn....18
3.4. Biến đổi dữ liệu cho phân cụm....19
3.5. Thiết kế chống rò rỉ dữ liệu....20
CHƯƠNG 4: XÂY DỰNG MÔ HÌNH HÓA (MODELING)....22
4.1. Khai phá luật kết hợp (Market Basket Analysis)....22
4.2. Phân cụm khách hàng theo RFM....27
4.3. Dự đoán khách hàng rời bỏ, ngừng mua (Churn)....31
CHƯƠNG 5: ĐÁNH GIÁ MÔ HÌNH VÀ PHÂN TÍCH KẾT QUẢ....36
5.1. Thước đo đánh giá và kết quả tổng hợp....36
5.2. Phân tích kết quả mô hình Churn....37
5.3. Đánh giá kết quả phân cụm....40
5.4. Đánh giá luật kết hợp....40
5.5. Đối chiếu chéo phân khúc RFM với nguy cơ Churn....41
5.6. Ý nghĩa thực tiễn và đề xuất hành động....42

CHƯƠNG 6: TRIỂN KHAI, TÁI LẬP VÀ SẢN PHẨM DEMO…….....44
6.1. Kiến trúc mã nguồn.....44
6.2. Tái lập kết quả.....45
6.3. Ứng dụng Demo Streamlit.....45
6.4. Kết quả Demo.....46
CHƯƠNG 7: TỔNG KẾT, TỰ ĐÁNH GIÁ VÀ PHÂN CÔNG CÔNG VIỆC.....51
7.1. Tổng kết.....51
7.2. Đóng gói của dự án.....51
7.3. Hạn chế.....52
7.4. Hướng phát triển.....53
7.5. Phân công công việc.....53
TÀI LIỆU THAM KHẢO.....55

CHƯƠNG 1: GIỚI THIỆU VÀ HIỂU BÀI TOÁN NGHIỆP VỤ.

1.1. Bối cảnh bài toán.

- Thương mại điện tử bán lẻ tạo ra lượng giao dịch lớn nhưng hành vi mua của khách hàng rất không đồng đều, một số ít khách mua thường xuyên với giá trị cao, trong khi nhiều khách chỉ mua một vài lần rồi không quay lại.
- Với doanh nghiệp, ba câu hỏi thực tiễn thường đặt ra là:
    - Nên gợi ý những sản phẩm nào để khách mua kèm.
    - Nên phân bổ nguồn lực chăm sóc theo những nhóm khách nào.
    - Nên can thiệp vào những khách nào đang có dấu hiệu ngừng mua.
- Bộ dữ liệu *Online Retail II* ghi lại giao dịch của một doanh nghiệp bán lẻ trực tuyến có trụ sở tại Vương quốc Anh, chủ yếu bán đồ quà tặng, trong đó nhiều khách hàng là nhà bán buôn.
- Dữ liệu có đủ ba thành phần cần thiết cho các câu hỏi trên: nội dung giỏ hàng, định danh khách hàng và mốc thời gian giao dịch.
- Nhóm chọn bộ dữ liệu này vì nó cho phép trả lời cả ba câu hỏi bằng ba kỹ thuật khai phá dữ liệu khác nhau trên cùng một nguồn, từ đó đối chiếu kết quả giữa các kỹ thuật thay vì xem chúng như ba bài toán rời rạc.

1.2. Từ mục tiêu nghiệp vụ đến mục tiêu khai phá dữ liệu.

- Mỗi mục tiêu nghiệp vụ được chuyển thành một mục tiêu khai phá dữ liệu cụ thể, kèm kỹ thuật và thước đo thành công.
- Cách chuyển đổi này giúp mọi kết quả ở các chương sau đều quay về một câu hỏi nghiệp vụ rõ ràng.

Bảng 1. Từ mục tiêu nghiệp vụ đến mục tiêu khai phá dữ liệu.

Mục tiêu nghiệp vụ	Câu hỏi	Mục tiêu khai phá dữ liệu	Kỹ thuật	Thước đo thành công
Tăng giá trị giỏ hàng	Sản phẩm nào thường được mua cùng nhau?	Tìm tập sản phẩm phổ biến và luật kết hợp $A \rightarrow B$	Apriori, FP-Growth	Support, Confidence, Lift, Kulczynski; số luật; thời gian chạy

Phân bổ chăm sóc theo giá trị khách hàng	Khách hàng chia thành những nhóm nào, giá trị mỗi nhóm ra sao?	Gom cụm khách theo Recency, Frequency, Monetary	K-Means, K-Medoids (PAM)	Silhouette, ARI giữa hai thuật toán, độ ổn định bootstrap, khả năng diễn giải
Giữ chân khách hàng	Khách hàng nào sẽ không quay lại mua trong thời gian tới?	Phân lớp nhị phân: Churn = 1 nếu không mua lại trong cửa sổ W ngày	Decision Tree, Random Forest, Naive Bayes	Precision, Recall, F1, AUC so với baseline; kiểm định chéo; Test tách theo thời gian
Hành động nhất quán theo từng nhóm khách	Rủi ro rời bỏ và sản phẩm nên gợi ý khác nhau thế nào giữa các nhóm?	Đối chiếu ba kết quả ở mức phân khúc	Phân tích chéo	Chênh lệch tỷ lệ Churn giữa các phân khúc; luật kết hợp riêng của từng phân khúc

1.3. Phạm vi, giả định và tiêu chí thành công.

- Phạm vi: Dự án dùng dữ liệu của một doanh nghiệp trong giai đoạn 12/2009 đến 12/2011. Đơn vị phân tích là hoá đơn (luật kết hợp) và khách hàng có định danh (phân cụm, dự đoán Churn). Dự án không ước lượng doanh thu thuần hay lợi nhuận và không kiểm chứng hiệu quả của các hành động đề xuất bằng thử nghiệm A/B.
- Giả định: Mỗi Customer ID đại diện cho một khách hàng. Churn là định nghĩa vận hành "không mua lại trong W ngày", không chứng minh khách đã rời doanh nghiệp vĩnh viễn. Các dòng bán hợp lệ sau làm sạch phản ánh hành vi mua thực tế.
- Tiêu chí thành công được xác định trước khi khi mô hình hóa:
  - Quy trình chạy lại được từ dữ liệu thô đến kết quả cuối.
  - Mô hình Churn vượt Baseline "Đoán tất cả là Churn" trên tập Test tách theo thời gian, đánh giá bằng F1 và AUC, không chỉ Accuracy.
  - Phân khúc diễn giải được theo nghiệp vụ và ổn định khi lấy mẫu lại (ARI bootstrap trên 0.9).
  - Luật kết hợp có Lift lớn hơn 1, kèm thước đo không bị ảnh hưởng bởi giao dịch rỗng (Kulczynski) và được phân tích theo từng phân khúc.

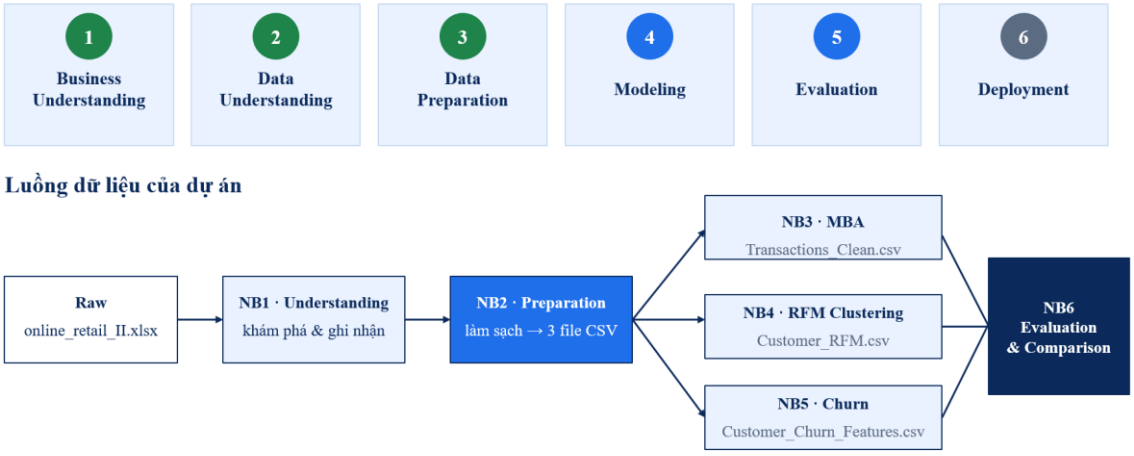
- Có sản phẩm minh hoạ trực quan để người không chuyên sử dụng kết quả.

1.4. Quy trình CRISP-DM và kiến trúc dự án.

Bảng 2. Các pha CRISP-DM và vị trí tương ứng trong dự án.

Pha	Nội dung thực hiện	Notebook	Module chính
Business Understanding	Xác định mục tiêu, phạm vi, tiêu chí thành công	–	–
Data Understanding	Khám phá chất lượng, phân phối, ngoại lai	01	Utils/Visualization.py
Data Preparation	Làm sạch, tạo RFM, đặc trưng, sinh nhãn Churn	02, 05	Preprocessing/Cleaning.py, Feature_Engineering.py; RFM/RFM_Calculator.py; Churn/Label_Generator.py
Modeling	Luật kết hợp, phân cụm, phân lớp, tinh chỉnh	03, 04, 05	MBA/Association_Rules.py; RFM/Clustering.py; Churn/Models.py
Evaluation	So sánh thuật toán, đối chiếu chéo, ý nghĩa thực tiễn	05, 06	Churn/Evaluation.py
Deployment	Ứng dụng Demo, tái lập kết quả	06	Demo/ (Streamlit)

Hình 1. Quy trình CRISP-DM và kiến trúc Pipeline



CHƯƠNG 2: HIỂU DỮ LIỆU (DATA UNDERSTANDING).

2.1. Nguồn dữ liệu và cấu trúc dữ liệu.

- Bộ dữ liệu *Online Retail II* công bố trên *UCI Machine Learning Repository*, gồm giao dịch từ 01/12/2009 đến 09/12/2011 (738 ngày).
- Dữ liệu nằm ở hai Sheet (Year 2009-2010 và Year 2010-2011); nhóm gộp thành một bảng 1,067,371 dòng và thêm cột Sheet để truy vết nguồn gốc.
- Mỗi dòng là một sản phẩm trong một hoá đơn, nên nhiều dòng cùng Invoice không phải các đơn hàng độc lập. Bảng 3 dưới đây mô tả 8 thuộc tính gốc của dữ liệu.

Bảng 3. Thuộc tính gốc dữ liệu Online Retail II.

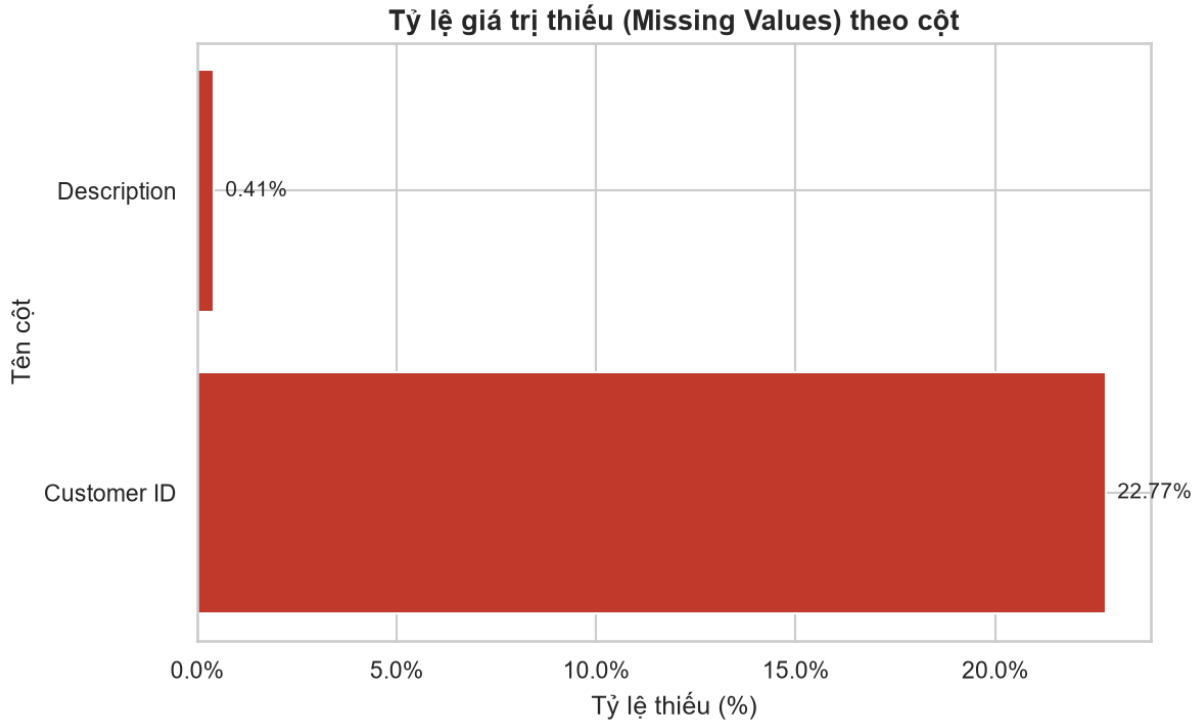
Thuộc tính	Kiểu	Ý nghĩa – Ghi chú
Invoice	Chuỗi	Mã hoá đơn; tiền tố "C" là hoá đơn huỷ, tiền tố "A" là bút toán điều chỉnh. 53,628 hoá đơn khác nhau
StockCode	Chuỗi	Mã sản phẩm, gồm cả mã phi sản phẩm (POST, DOT, M, D...). 5,305 mã khác nhau
Description	Chuỗi	Tên sản phẩm; thiếu ở 4,382 dòng
Quantity	Số nguyên	Số lượng trên dòng; có giá trị âm
InvoiceDate	Thời gian	Ngày giờ lập hoá đơn
Price	Số thực	Đơn giá (GBP)
Customer ID	Số thực	Mã khách hàng; thiếu ở 22.77% số dòng. 5,942 khách khác nhau
Country	Chuỗi	Quốc gia của khách; 43 giá trị

2.2. Chất lượng dữ liệu.

- Nhóm kiểm tra dữ liệu thiếu, dòng trùng, giá trị bất thường và các mã không phải sản phẩm.
- Kết quả được tổng hợp ở Bảng 4.
- Tỷ lệ thiếu theo cột được minh hoạ ở Hình 2.

Bảng 4. Các vấn đề chất lượng dữ liệu phát hiện được.

Vấn đề	Số liệu	Hướng xử lý
Customer ID thiếu	243,007 dòng (22.77%); riêng UK thiếu 24.46%	Giữ cho luật kết hợp; loại khi tính RFM và Churn
Description thiếu	4,382 dòng (0.41%)	Dùng StockCode làm khoá; tên hiển thị lấy theo mô tả phổ biến nhất của mã
Dòng trùng hoàn toàn	34,335 dòng (3.22%) khi so sánh 8 cột gốc, bỏ cột Sheet	Loại dòng trùng hoàn toàn, bỏ cột Sheet khi so sánh
Hoá đơn huỷ	19,494 dòng (1.83%); 8,292 trên 53,628 hoá đơn (15.46%)	Loại hóa đơn hủy; chưa đối trừ với đơn gốc
Quantity âm ngoài hoá đơn huỷ	3,457 dòng, đều có Price = 0 và thiếu Customer ID; 481 dòng có mô tả kiểu "damaged", "lost", "missing"	Loại Quantity âm ngoài hoá đơn huỷ
Bút toán "Adjust bad debt"	6 dòng, Price từ −53,594.36 đến 11,062.06	Loại bút toán "Adjust bad debt" (Invoice bắt đầu bằng "A")
StockCode không phải sản phẩm	5,821 dòng (0.55%), chiếm 4.05% giá trị giao dịch dương (£849,238 trên £20,972,968)	Loại StockCode không phải sản phẩm (13 mã)
Price = 0	6,202 dòng (0.58%); 3,457 dòng thuộc nhóm 5	Dòng Price = 0 còn lại giữ nguyên vì không làm đổi Monetary

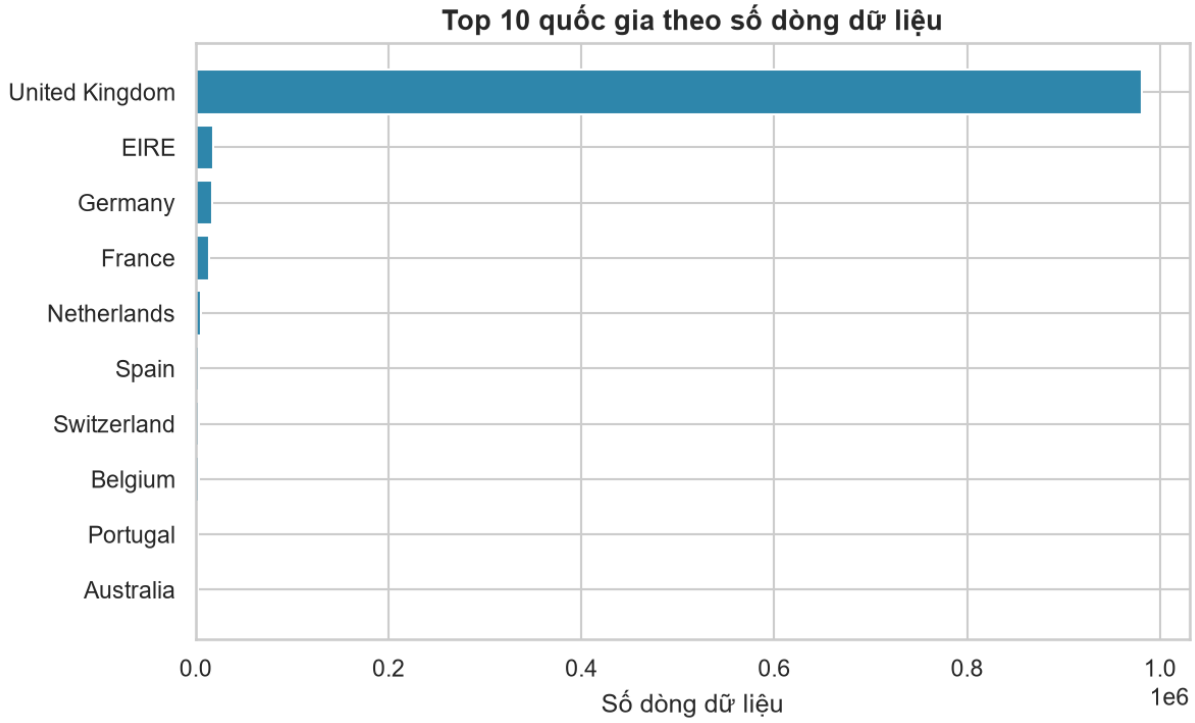


Hình 2. Tỷ lệ giá trị thiếu theo cột.

- Ta thấy 22.77% dòng không có Customer ID nên không thể gắn với khách hàng; nhóm không gán mã giả hay nội suy.
- Các mã như POST, DOT hay BANK CHARGES là khoản phí và điều chỉnh, không phản ánh nhu cầu mua sản phẩm; giữ chúng sẽ làm sai cả tổng giá trị lẫn luật kết hợp (ví dụ POST xuất hiện trong rất nhiều giỏ hàng).

2.3. Phân bố theo quốc gia và thời gian.

- Dữ liệu gồm 43 quốc gia, nhưng United Kingdom chiếm 981,330 dòng (91.94% tổng số dòng), tiếp theo là EIRE (17,866 dòng), Germany (17,624) và France (14,330).
- Do đó các kết luận của dự án chủ yếu phản ánh thị trường Anh. Tỷ lệ thiếu Customer ID cũng không đồng đều giữa các nước (UK 24.46%, EIRE 9.35%), nên tập khách có định danh có thể lệch so với toàn bộ khách mua.



Hình 3. Mười quốc gia có nhiều dòng dữ liệu nhất.

- Về thời gian, dữ liệu kéo dài 738 ngày và tháng 12/2011 chỉ có đến ngày 09.
- Điều này ảnh hưởng trực tiếp đến thiết kế nhãn Churn: cửa sổ quan sát nhãn của tập Test kết thúc đúng ở ngày cuối của dữ liệu.

2.4. Ngoại lai và quyết định xử lý.

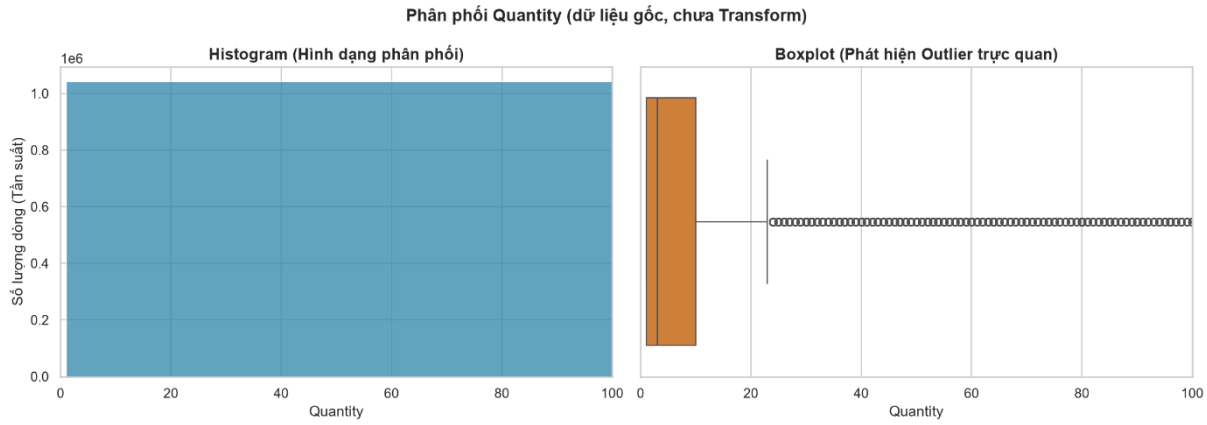
- Quantity lệch phải cực mạnh (độ lệch 459.99 trước khi biến đổi, còn 1.06 sau log1p). Nhóm so sánh ba cách phát hiện ngoại lai.
- Quy tắc IQR (Q1 = 1, Q3 = 10, cận trên 23.5) đánh dấu tới 10.69% số dòng, trong khi *Z-Score* trên dữ liệu gốc chỉ đánh dấu 0.15% vì bản thân độ lệch chuẩn đã bị các giá trị lớn kéo giãn. Z-score sau log1p cho kết quả trung gian (0.95%).

Bảng 5. Số ngoại lai của Quantity theo ba cách phát hiện.

Phương pháp	Số dòng bị đánh dấu	Tỷ lệ
IQR (cận 1.5 × IQR)	111,341	10.69%
Z-Score trên Quantity gốc ($\|z\| > 3$)	1,590	0.15%
Z-Score trên log1p(Quantity) ($\|z\| > 3$)	9,939	0.95%

```
[IQR] Q1 = 1.0, Q3 = 10.0, IQR = 9.0, cận = (-12.5, 23.5)
[IQR] Số outlier phát hiện: 111,341 (10.69%)

[Z - Score, dữ liệu gốc] Số Outlier phát hiện: 1,590 (0.15%)
[Z - Score, sau log1p] Số Outlier phát hiện: 9,939 (0.95%)
```



Hình 4. Phân phối của Quantity: Histogram và Boxplot.

- Giả thuyết bán buôn: Nhóm kiểm tra giả thuyết "Quantity lớn là đơn bán buôn hợp lệ".
- Nhóm dòng có Quantity từ phân vị 99 trở lên (13,524 dòng) có giá trung vị £1.06,

thấp hơn mức £2.10 của toàn bộ dữ liệu, tức là các mặt hàng đơn giá thấp được mua với số lượng lớn, đúng với mô tả của nguồn dữ liệu về nhiều khách là nhà bán buôn.

- Vì vậy nhóm không loại ngoại lai Quantity khỏi dữ liệu và xử lý độ lệch bằng biến đổi log1p ở bước phân cụm.

```
Ngưỡng Quantity cao (Percentile 99): 100
Số dòng thuộc nhóm Quantity cao     : 13,524

Price trung vị của nhóm Quantity cao: £1.06
Price trung vị của toàn bộ dữ liệu  : £2.10
```

- Hai giao dịch lớn nhất là hoá đơn 581483 (80,995 đơn vị, khách 16446) và 541431 (74,215 đơn vị, khách 12346). Giá trị cực lớn như vậy cần được đối chiếu với hoá đơn huỷ tương ứng trước khi kết luận là đơn thật.

	Invoice	StockCode	Description	# Quantity	# Price	# Customer ID	Country
1065882	581483	23843	PAPER CRAFT , LITTLE BIRDIE	80995	2.08	16446.0	United Kingdom
587080	541431	23166	MEDIUM CERAMIC TOP STORAGE JAR	74215	1.04	12346.0	United Kingdom
90857	497946	37410	BLACK AND WHITE PAISLEY FLOWER MUG	19152	0.1	13902.0	Denmark
127166	501534	21099	SET/6 STRAWBERRY PAPER CUPS	12960	0.1	13902.0	Denmark
127168	501534	21091	SET/6 WOODLAND PAPER PLATES	12960	0.1	13902.0	Denmark

2.5. Tóm tắt phát hiện và hệ quả thiết kế.

- Dữ liệu lệch phải mạnh: Dùng log1p cho Frequency và Monetary trước khi phân cụm; giữ ngoại lai vì có thể là đơn bán buôn hợp lệ.
- 22.77% dòng thiếu Customer ID: Luật kết hợp dùng mọi hoá đơn, còn RFM và Churn chỉ dùng khách có định danh. Hai bài toán vì vậy có tập quan sát khác nhau.
- Hóa đơn hủy, bút toán và mã phí: Làm sạch theo năm bước.
- United Kingdom chiếm 91.94% số dòng: Phạm vi kết luận giới hạn ở thị trường Anh.
- Dữ liệu kết thúc ngày 09/12/2011: Ảnh hưởng đến cách chọn mốc Snapshot và cửa sổ nhãn Churn.

CHƯƠNG 3: CHUẨN BỊ DỮ LIỆU (DATA PREPARATION).

Chương này trình bày các bước biến dữ liệu thô thành các tập đầu vào cho ba bài toán, kèm lý do kỹ thuật của từng bước, các biện pháp chống rò rỉ dữ liệu và kế hoạch đo tác động của tiền xử lý lên kết quả cuối.

3.1. Làm sạch dữ liệu theo năm bước.

- Quy trình làm sạch được cài đặt trong ***Source/Preprocessing/Cleaning.py*** thành năm hàm độc lập, nối với nhau bằng hàm ***clean_transactions()***.
- Mỗi hàm in ra số dòng bị loại để có thể kiểm tra lại.
- Thứ tự các bước đi từ các giao dịch rõ ràng không phải bán hàng đến các dòng trùng lặp.

Bảng 6. Các bước làm sạch dữ liệu.

Bước	Quy tắc	Số dòng loại	Dòng còn lại	Lý do kỹ thuật
0	Dữ liệu gộp từ hai sheet	–	1,067,371	–
1	Loại hoá đơn huỷ	19,494	1,047,877	Giao dịch hoàn trả không phản ánh hành vi mua thành công
2	Loại bút toán "Adjust bad debt"	6	1,047,871	Bút toán kế toán, có Price âm lớn
3	Loại Quantity âm ngoài hoá đơn huỷ	3,457	1,044,414	Điều chỉnh kho (Price = 0, thiếu Customer ID), không phải giao dịch bán
4	Loại StockCode không phải sản phẩm (13 mã)	4,613	1,039,801	Phí vận chuyển, chiết khấu, phí ngân hàng, dữ liệu thử
5	Loại dòng trùng hoàn toàn, bỏ cột Sheet khi so sánh	33,788	1,006,013	Tránh đếm lặp cùng một dòng; xem lưu ý bên dưới

```
======================================================================
Số dòng ban đầu: 1,067,371
----------------------------------------------------------------------
[Remove Cancelled Invoices] Đã loại 19,494 dòng Invoice huỷ (Còn lại 1,047,877 dòng).
[Remove bad debt Adjustments] Đã loại 6 dòng 'Adjust bad debt' (Còn lại 1,047,871 dòng).
[Remove Stock Adjustment_rows] Đã loại 3,457 dòng Quantity âm bất thường (Còn lại 1,044,414 dòng).
[Remove non Product Stock Codes] Đã loại 4,613 dòng StockCode phi sản phẩm (Còn lại 1,039,801 dòng).
[Remove Duplicate Rows] Đã loại 33,788 dòng trùng lặp (Còn lại 1,006,013 dòng).
----------------------------------------------------------------------
Số dòng sau khi làm sạch: 1,006,013 (đã loại tổng cộng 61,358 dòng, tương đương 5.75%)
======================================================================
```

- Ba quyết định cần giải thích:
  - Thứ nhất, hoá đơn huỷ bị loại để phân tích hành vi mua thành công, đổi lại, nhóm chưa đối trừ ngược các đơn gốc bị huỷ, đây là một hạn chế.
  - Thứ hai, các mã POST, DOT, M, D, BANK CHARGES, AMAZONFEE... bị loại vì là phí hoặc điều chỉnh; danh sách 13 mã được khai báo tường minh trong mã nguồn nên có thể kiểm tra và chỉnh sửa.
  - Thứ ba, dòng trùng hoàn toàn có thể xuất phát từ hai nguyên nhân, ghi trùng, hoặc hai Sheet nguồn có khoảng thời gian chồng lấn nhau. Nhóm chọn loại chúng, nhưng thừa nhận có thể một số dòng giống hệt là hai dòng hàng hợp lệ (cùng sản phẩm, cùng số lượng trong một hoá đơn).

3.2. Dữ liệu sau làm sạch và xử lý giá trị thiếu.

- Sau làm sạch dữ liệu còn 1,006,013 dòng.
- Thống kê mô tả sau làm sạch, ta thấy lệch phải mạnh, trung bình của Quantity (11.36) gấp gần ba lần trung vị.
- Giá trị lớn nhất của *TotalPrice* lên tới £168,469.60 so với trung vị £10.00.

Bảng 7. Thống kê mô tả sau làm sạch.

Biến	Trung bình	Trung vị	Độ lệch chuẩn	Lớn nhất
Quantity	11.36	4.00	131.72	80,995
Price (£)	3.33	2.10	4.78	1,157.15
TotalPrice = Quantity × Price	19.53	10.00	199.72	168,469.60

···	# Quantity	# Price	# TotalPrice
count	1006013.0	1006013.0	1006013.0
mean	11.363632477910325	3.3337008666886017	19.528921435408886
std	131.71777227569757	4.7783895608641425	199.72049677934328
min	1.0	0.0	0.0
25%	1.0	1.25	3.95
50%	4.0	2.1	10.0
75%	12.0	4.13	17.700000000000003
max	80995.0	1157.15	168469.6

- Xử lý giá trị thiếu:
  - Customer ID thiếu ở 229,371 dòng (22.80% sau làm sạch).
  - Với luật kết hợp, các dòng này vẫn được dùng vì mỗi hoá đơn là một giỏ hàng, không cần biết khách là ai.
  - Với RFM và Churn, các dòng này bị loại (còn 776,642 dòng, tương ứng 5,853 khách hàng) vì không thể gắn hành vi mua với một khách cụ thể; nhóm không gán mã giả hay nội suy.
  - Description thiếu không ảnh hưởng mô hình vì toàn bộ phân tích dùng StockCode làm khoá, còn tên sản phẩm chỉ để hiển thị.

3.3. Tạo đặc trưng RFM và đặc trưng Churn.

- Cột *TotalPrice* = *Quantity* × *Price* được tạo trong ***Feature_Engineering.py*** và dùng chung cho các bài toán.
- Với mỗi khách hàng, hàm ***calculate_rfm()*** tính ba chỉ số tại một mốc *Snapshot s*:
  - Recency là số ngày từ lần mua gần nhất đến *s*.
  - Frequency là số hoá đơn khác nhau.
  - Monetary là tổng *TotalPrice*.

Bảng 8. Thống kê mô tả RFM toàn kỳ.

Chỉ số	Trung bình	Trung vị	Nhỏ nhất	Lớn nhất
Recency (Ngày)	199.17	94	0	738
Frequency (Hoá đơn)	6.25	3	1	373
Monetary (£)	2,916.34	856.01	0.00	580,987.04

Thống kê RFM (toàn kỳ):

···	# Customer ID	# Recency	# Frequency	# Monetary
count	5853.0	5853.0	5853.0	5853.0
mean	15319.354519050059	199.16623953528105	6.253203485392107	2916.3358568255594
std	1714.995564510493	208.5059591593103	12.75197673038328	14305.788772036964
min	12346.0	0.0	1.0	0.0
25%	13837.0	24.0	1.0	339.5
50%	15320.0	94.0	3.0	856.01
75%	16802.0	378.0	7.0	2240.9
max	18287.0	738.0	373.0	580987.04

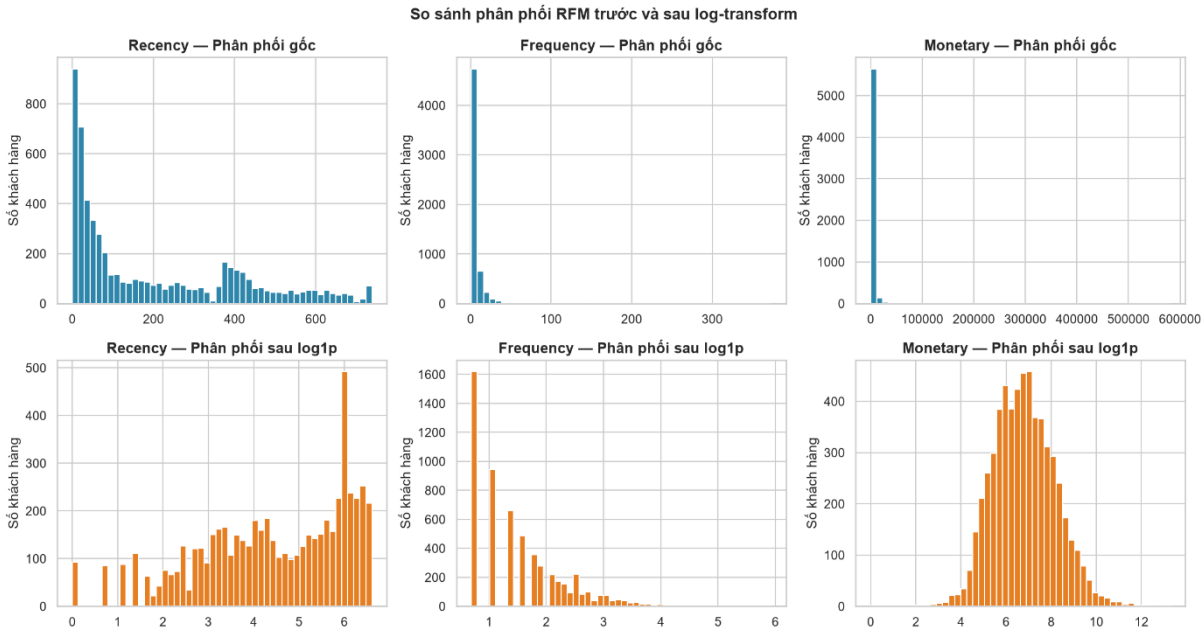
- Hàm chỉ dùng giao dịch có thời gian không muộn hơn *s*, nên có thể gọi lại với bất kỳ mốc nào mà không làm rò rỉ thông tin tương lai.
- Với dữ liệu toàn kỳ, bảng RFM có 5,853 khách hàng. Phân phối rất lệch: Monetary trung bình £2,916 nhưng trung vị chỉ £856, và khách chi nhiều nhất đạt £580,987.
- Với bài toán Churn, ngoài ba chỉ số RFM tại Snapshot, nhóm bổ sung ba đặc trưng phản ánh nhịp mua của từng khách trong hàm ***add_churn_features()***.
- Đặc trưng *AvgGapDays* của khách chỉ mua một lần không tính được; nhóm điền bằng chính Tenure của khách đó thay vì 0, vì "im lặng suốt từ lần mua đầu đến giờ" hợp lý hơn "mua cách nhau 0 ngày".

Bảng 9. Sáu đặc trưng dùng cho bài toán Churn.

Đặc trưng	Cách tính	Ý nghĩa nghiệp vụ
Recency	Số ngày từ lần mua cuối đến *Snapshot*	Mức độ rời bỏ của khách
Frequency	Số hoá đơn khác nhau trước *Snapshot*	Mức độ gắn bó của khách
Monetary	Tổng *TotalPrice* trước *Snapshot*	Giá trị chi tiêu
AvgOrderValue	*Monetary* ÷ *Frequency*	Quy mô mỗi lần mua
Tenure	Số ngày từ lần mua đầu đến *Snapshot*	Độ dài quan hệ với khách
AvgGapDays	Trung bình khoảng cách giữa các ngày mua; khách mua một lần: bằng *Tenure*	Chu kỳ mua riêng của khách

3.4. Biến đổi dữ liệu cho phân cụm.

- K− Means và K− Medoids dùng khoảng cách Euclid nên rất nhạy với thang đo và độ lệch.
- Nhóm áp dụng hai bước trong ***prepare_rfm_features()*** biến đổi $\mathbf{log1p(x) = ln(1 + x)}$ cho *Frequency* và *Monetary* (có chặn dưới bằng 0 để tránh log của số âm), rồi chuẩn hoá Z−Score cho cả ba chỉ số.
- Recency được giữ nguyên vì nằm trong khoảng giới hạn 0 đến 738 ngày và không lệch mạnh như hai chỉ số còn lại.



Hình 5. Phân phối RFM trước và sau biến đổi $\log 1p$.

3.5. Thiết kế chống rò rỉ dữ liệu.

- Với bài toán dự đoán theo thời gian, rò rỉ dữ liệu là rủi ro lớn nhất, chỉ cần một đặc trưng, một ngưỡng hay một bước cân bằng lớp dùng thông tin từ tương lai là kết quả đánh giá trở nên vô nghĩa.
- Bảng dưới đây liệt kê các nguy cơ nhóm đã nhận diện và biện pháp tương ứng.

Bảng 10. Các biện pháp chống rò rỉ dữ liệu.

Nguy cơ rò rỉ dữ liệu	Biện pháp chống rò rỉ
Đặc trưng dùng thông tin sau thời điểm dự đoán	Mọi đặc trưng chỉ dùng giao dịch có thời gian không muộn hơn Snapshot
Trộn ngẫu nhiên Train/Test khi dữ liệu có trục thời gian	Tách theo hai Snapshot: Train 28/07/2011, Test 03/10/2011; cửa sổ nhãn hai tập không chồng lấn
Chọn ngưỡng Churn bằng toàn bộ dữ liệu	P75 của khoảng cách giữa hai lần mua chỉ tính trên giao dịch trước Snapshot Train
Cân bằng lớp trước khi chia tập	SMOTE chỉ áp dụng trên Train; Test giữ phân bố thật
Đối chiếu phân khúc dùng thông tin của cửa sổ nhãn	Tính lại RFM và phân khúc tại Snapshot Test

- Cửa sổ Churn và vòng phụ thuộc:
  - Độ dài cửa sổ W quyết định mốc Snapshot, nhưng W lại được chọn từ phân phối khoảng cách mua, vốn phải tính từ dữ liệu trước Snapshot.
  - Nhóm giải quyết bằng hai bước: dùng W = 70 ngày (P75 tính trên toàn kỳ) chỉ để xác định mốc Train sơ bộ là 22/07/2011; sau đó tính lại P75 chỉ từ giao dịch đến hết ngày đó (573,924 trên 776,642 dòng; 19,884 khoảng cách từ 3,460 khách mua lặp lại), được W chính thức = 67 ngày.
  - Hai Snapshot cuối cùng là 28/07/2011 và 03/10/2011. Mốc cắt 22/07 sớm hơn mốc Train 28/07 nên không có rò rỉ, chỉ là dùng ít thông tin hơn mức cho phép.

```
[Build Time Based Snapshots] Ngày cuối dữ liệu: 2011-12-09
  TRAIN: Snapshot = 2011-07-22, cửa sổ quan sát nhãn = (2011-07-22, 2011-09-30]
  TEST : Snapshot = 2011-09-30, cửa sổ quan sát nhãn = (2011-09-30, 2011-12-09]
[Build Time Based Snapshots] Ngày cuối dữ liệu: 2011-12-09
  TRAIN: Snapshot = 2011-07-22, cửa sổ quan sát nhãn = (2011-07-22, 2011-09-30]
  TEST : Snapshot = 2011-09-30, cửa sổ quan sát nhãn = (2011-09-30, 2011-12-09]
[Compute Inter Purchase Gaps] Đã lọc theo cutoff_date = 2011-07-22: còn 573,924/776,642 dòng giao dịch.
[Compute Inter Purchase Gaps] Thu được 19,884 khoảng cách từ 3,460 khách mua lặp lại.
[Compute Inter Purchase Gaps] Có 1,621 khách chỉ mua đúng 1 lần (31.9%)
[Suggest Churn Window] Cửa sổ Churn đề xuất theo P75: 67 ngày.
  ⇒ Khách hàng không quay lại mua trong 67 ngày được coi là đã rời bỏ, vì 75% các chu kỳ mua thực tế đều ngắn hơn khoảng này.

So sánh: P75 sơ bộ (toàn kỳ)   = 70 ngày
         P75 chính thức (Train) = 67 ngày
```

CHƯƠNG 4: XÂY DỰNG MÔ HÌNH HÓA (MODELING).

Chương này trình bày ba nhóm mô hình. Với mỗi nhóm, nhóm nêu cơ sở lý thuyết, thiết kế thực nghiệm, so sánh phản biện giữa các thuật toán và kết quả huấn luyện.

4.1. Khai phá luật kết hợp (Market Basket Analysis).

4.1.1. Cơ sở lý thuyết.

- Gọi D là tập các giỏ hàng (mỗi hoá đơn là một giỏ), A và B là hai tập sản phẩm rời nhau. Bốn thước đo được dùng là:

$$Support(A) = |\{T \in D : A \subseteq T\}| \,/\, |D| \quad (1)$$

$$Confidence(A \to B) = Support(A \cup B) \,/\, Support(A) \quad (2)$$

$$Lift(A \to B) = Confidence(A \to B) \,/\, Support(B) \quad (3)$$

$$Kulczynski(A,\ B) = \frac{1}{2}\,[\,P(B \mid A) + [P(A \mid B)\,] \quad (4)$$

- Support cho biết mức phổ biến của tập sản phẩm.
- Confidence là xác suất có B khi đã có A.
- Lift lớn hơn 1 cho thấy A và B xuất hiện cùng nhau nhiều hơn mức kỳ vọng nếu độc lập.
- Kulczynski là trung bình của hai xác suất có điều kiện theo hai chiều và không thay đổi khi thêm nhiều giỏ hàng không chứa A lẫn B, tính chất null-invariant.
- Điều này quan trọng với dữ liệu giỏ hàng thưa, nơi phần lớn giao dịch không chứa cặp sản phẩm đang xét và Lift dễ bị thổi phồng ở vùng Support thấp.

4.1.2. So sánh phản biện Apriori và FP−Growth.

- Apriori dựa trên tính chất mọi tập con của một tập phổ biến cũng phải phổ biến. Thuật toán sinh các tập ứng viên theo từng mức (kích thước 1, 2, 3...) và quét cơ sở dữ liệu ở mỗi mức để đếm Support. Ưu điểm là dễ hiểu, dễ cài đặt; nhược điểm là số ứng viên có thể tăng rất nhanh khi ngưỡng Support thấp và phải quét dữ liệu nhiều lần.
- FP−Growth nén cơ sở dữ liệu thành cây FP-Tree sau hai lần quét, rồi khai phá bằng cách chia để trị trên các cây điều kiện mà không sinh tập ứng viên. Ưu điểm là tránh sinh ứng viên, thường hiệu quả khi tập phổ biến nhiều và dài; nhược điểm là chi phí dựng cây và bộ nhớ cho cây. Về độ phức tạp, cả hai đều có trường hợp

xấu nhất theo hàm mũ của số sản phẩm; hiệu năng thực tế phụ thuộc mật độ dữ liệu và ngưỡng Support, nên nhóm đo trực tiếp thay vì giả định thuật toán nào nhanh hơn.

4.1.3. Thiết kế thực nghiệm.

- Mỗi hoá đơn là một giỏ hàng; có 41,383 hoá đơn và 4,971 mã sản phẩm, biểu diễn bằng ma trận *one-hot* dạng thưa để tiết kiệm bộ nhớ.
- Nhóm chạy cả hai thuật toán bằng thư viện *mlxtend* ở ba ngưỡng *min_support* là 0.02, 0.01 và 0.005; tập luật cuối cùng được sinh từ FP−Growth ở *min_support* = 0.005 với Confidence tối thiểu 0.3, rồi bổ sung Kulczynski.
- Nhóm kiểm tra tính đúng đắn bằng cách yêu cầu hai thuật toán phải cho cùng số *itemsets* ở mọi ngưỡng.

4.1.4. Kết quả Benchmark.

- Hai thuật toán cho cùng số *itemsets* ở cả ba ngưỡng như bảng dưới, nên chúng giải cùng một bài toán và chỉ khác về hiệu năng.
- Số *itemsets* tăng rất nhanh khi giảm ngưỡng (290, 1,223 rồi 6,863).
- Ở ngưỡng cao Apriori nhanh hơn rõ rệt (FP−Growth chậm gấp 2.69 lần ở 0.02), còn ở ngưỡng thấp nhất 0.005 FP−Growth nhanh hơn (chỉ bằng 0.65 thời gian của Apriori).
- Xu hướng này phù hợp với lý thuyết: chi phí dựng cây chỉ được bù đắp khi số *itemsets* lớn.
- Vì vậy không thuật toán nào nhanh hơn ở mọi ngưỡng, và nhóm chọn FP-Growth cho bước sinh luật vì cần ngưỡng thấp.

Bảng 11. So sánh Apriori và FP−Growth theo ngưỡng min_support.

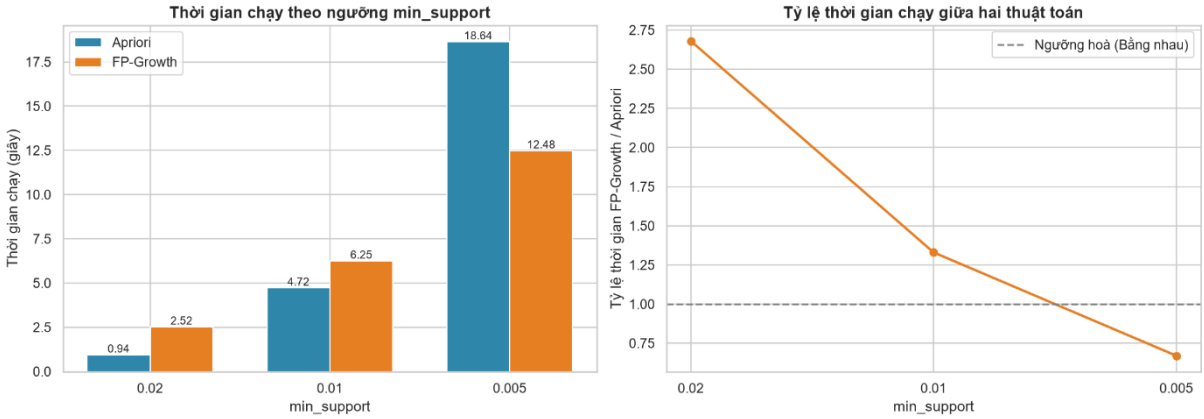
min_support	Số itemsets	Apriori (giây)	FP−Growth (giây)	FP-Growth / Apriori	Nhanh hơn
0,02	290	0,92	2,47	2.69	Apriori
0,01	1.223	4,73	6,16	1.30	Apriori
0,005	6.863	19,29	12,59	0.65	FP−Growth

```
 Đang chạy với min_support = 0.02
[Run Apriori] Min Support = 0.02: tìm được 290 Frequent Itemsets trong 0.94 giây.
[Run FP-Growth] Min Support = 0.02: tìm được 290 Frequent Itemsets trong 2.52 giây.

 Đang chạy với min_support = 0.01
[Run Apriori] Min Support = 0.01: tìm được 1,223 Frequent Itemsets trong 4.72 giây.
[Run FP-Growth] Min Support = 0.01: tìm được 1,223 Frequent Itemsets trong 6.25 giây.

 Đang chạy với min_support = 0.005
[Run Apriori] Min Support = 0.005: tìm được 6,863 Frequent Itemsets trong 18.64 giây.
[Run FP-Growth] Min Support = 0.005: tìm được 6,863 Frequent Itemsets trong 12.48 giây.
```

...	# min_support	# Số Itemsets	# Apriori (giây)	# FP-Growth (giây)	# Tỷ lệ FP-Growth / Apriori
0	0.02	290	0.94	2.52	2.68
1	0.01	1223	4.72	6.25	1.33
2	0.005	6863	18.64	12.48	0.67



Hình 6. Thời gian chạy Apriori và FP-Growth theo min_support.

4.1.5. Luật kết hợp trên toàn bộ hóa đơn.

- Ở *min_support* = 0.005 và Confidence tối thiểu 0.3, FP−Growth sinh 8,777 luật.
- Để hiển thị các luật có ý nghĩa thực tế, nhóm chỉ giữ luật dạng một sản phẩm sang một sản phẩm, loại luật trùng hai chiều (A → B và B → A có cùng Support và Lift) và yêu cầu Support từ 0.02.
- Năm luật có Lift cao nhất được liệt kê ở bảng dưới:

```
TOP 5 LUẬT KẾT HỢP CÓ LIFT CAO NHẤT (Support ≥ 0.02):

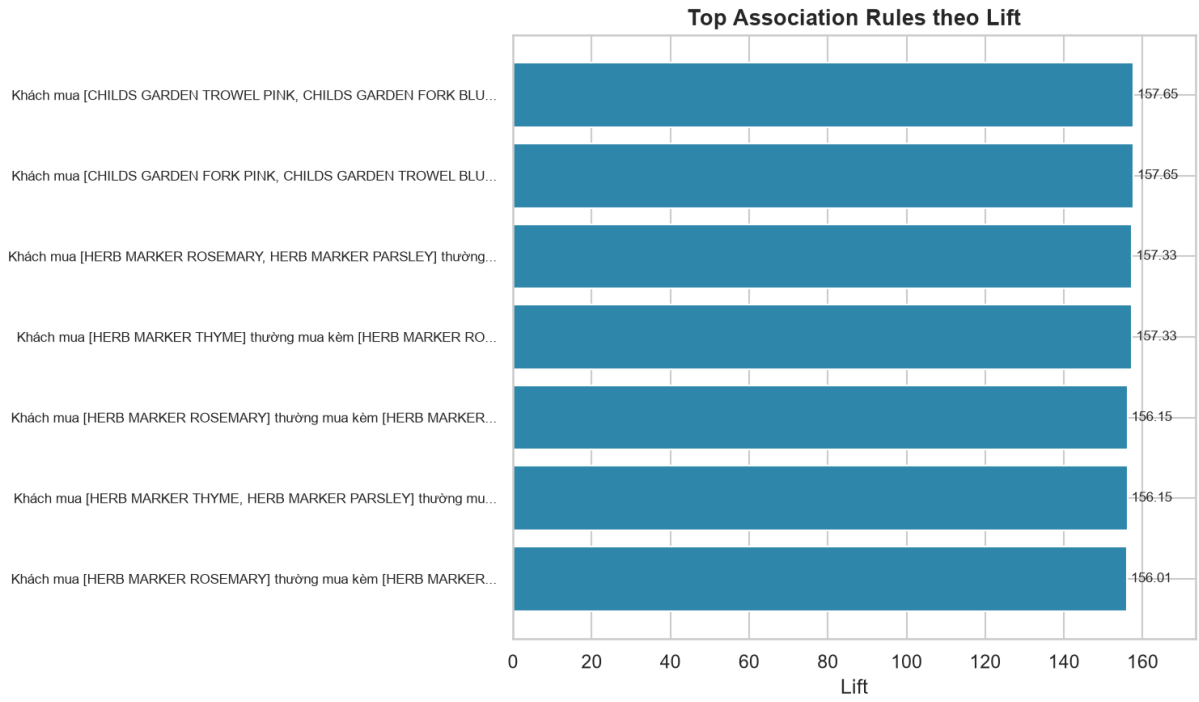
1. [PINK REGENCY TEACUP AND SAUCER] → [GREEN REGENCY TEACUP AND SAUCER]
   Support = 0.0209  |  Confidence = 0.837  |  Lift = 25.53  |  Kulczynski = 0.737

2. [GREEN REGENCY TEACUP AND SAUCER] → [ROSES REGENCY TEACUP AND SAUCER ]
   Support = 0.0250  |  Confidence = 0.763  |  Lift = 22.17  |  Kulczynski = 0.745

3. [ALARM CLOCK BAKELIKE RED ] → [ALARM CLOCK BAKELIKE GREEN]
   Support = 0.0202  |  Confidence = 0.613  |  Lift = 19.92  |  Kulczynski = 0.635

4. [DOLLY GIRL LUNCH BOX] → [SPACEBOY LUNCH BOX ]
   Support = 0.0200  |  Confidence = 0.621  |  Lift = 18.80  |  Kulczynski = 0.614

5. [CHARLOTTE BAG PINK POLKADOT] → [RED RETROSPOT CHARLOTTE BAG]
   Support = 0.0260  |  Confidence = 0.679  |  Lift = 13.78  |  Kulczynski = 0.604
```



Hình 7. Bảy luật kết hợp có Lift cao nhất.

- Điểm chung của các luật này là chúng nối các biến thể cùng một dòng sản phẩm (cùng mẫu, khác màu hoặc khác kiểu).
- Nếu không lọc theo Support, các luật có Lift cao nhất toàn bộ (tới khoảng 157) đều nằm sát ngưỡng *min_support* = 0.005, tức rất ít hoá đơn; chúng đáng tin cậy thấp hơn nhiều so với các luật ở bảng trên.
- Vì vậy Lift cao chỉ nên được đọc cùng Support và Kulczynski.

4.1.6. Luật kết hợp theo từng phân khúc.

- Để gắn luật kết hợp với phân khúc khách hàng, nhóm chạy FP−Growth riêng cho từng phân khúc trên các hoá đơn có Customer ID (36,600 trên 41,383 hoá đơn, tức 88.4%; 4,783 hoá đơn thiếu Customer ID bị loại khỏi bước này).
- Do quy mô các phân khúc rất khác nhau, nhóm dùng *min_support* = 0.01 tính trên số hoá đơn của chính phân khúc.

Bảng 12. Khai phá luật kết hợp riêng cho từng phân khúc.

Phân khúc	Số hóa đơn	Ma trận One-hot	Itemsets	Số luật	Ngưỡng tuyệt đối (hoá đơn)
Khách VIP	26,472	26,472 × 4,567	1,036	905	≈ 265

Khách hàng trung thành	6,869	6,869 × 4,190	713	196	≈ 69
Khách hàng có nguy cơ rời bỏ	3,259	3,259 × 3,622	689	199	≈ 33

```
====== Khách VIP ======
[Build Onehot Basket] Số hoá đơn (giỏ hàng): 26,472
[Build Onehot Basket] Kích thước ma trận Onehot: (26472, 4567)
[Run FP-Growth] Min Support = 0.01: tìm được 1,036 Frequent Itemsets trong 2.92 giây.
[Generate Rules] Sinh được 905 luật kết hợp  (Lọc theo confidence >= 0.3).

====== Khách hàng có nguy cơ rời bỏ ======
[Build Onehot Basket] Số hoá đơn (giỏ hàng): 3,259
[Build Onehot Basket] Kích thước ma trận Onehot: (3259, 3622)
[Run FP-Growth] Min Support = 0.01: tìm được 689 Frequent Itemsets trong 0.59 giây.
[Generate Rules] Sinh được 199 luật kết hợp  (Lọc theo confidence >= 0.3).

====== Khách hàng trung thành ======
[Build Onehot Basket] Số hoá đơn (giỏ hàng): 6,869
[Build Onehot Basket] Kích thước ma trận Onehot: (6869, 4190)
[Run FP-Growth] Min Support = 0.01: tìm được 713 Frequent Itemsets trong 0.58 giây.
[Generate Rules] Sinh được 196 luật kết hợp  (Lọc theo confidence >= 0.3).

                            Số luật  Lift trung bình  Lift lớn nhất
Khách VIP                       905           13.35          55.96
Khách hàng có nguy cơ rời bỏ    199           20.48          63.58
Khách hàng trung thành          196           20.41          51.50
```

- Số luật của nhóm VIP nhiều hơn hẳn chủ yếu vì nhóm này chiếm khoảng 72% số hoá đơn gán được, không phải vì hành vi mua phức tạp hơn.
- Ngưỡng 1% tương ứng khoảng 265 hoá đơn ở nhóm VIP nhưng chỉ khoảng 33 hoá đơn ở nhóm có nguy cơ rời bỏ, nên luật của các phân khúc nhỏ kém ổn định hơn. Chỉ 79 luật xuất hiện ở cả ba phân khúc (8.7% luật của VIP; 40.3% của nhóm trung thành; 39.7% của nhóm nguy cơ). Bảng dưới nêu ba luật 1 → 1 có Lift cao nhất của mỗi phân khúc:

```
====== TOP 3 LUẬT THEO LIFT — Khách VIP ======
1. Khách mua [POPPY'S PLAYHOUSE LIVINGROOM ] thường mua kèm [POPPY'S PLAYHOUSE KITCHEN]
   Support = 0.0106 | Confidence = 0.892 | Lift = 55.96
2. Khách mua [POPPY'S PLAYHOUSE KITCHEN] thường mua kèm [POPPY'S PLAYHOUSE LIVINGROOM ]
   Support = 0.0106 | Confidence = 0.666 | Lift = 55.96
3. Khách mua [POPPY'S PLAYHOUSE BEDROOM ] thường mua kèm [POPPY'S PLAYHOUSE KITCHEN]
   Support = 0.0125 | Confidence = 0.851 | Lift = 53.38

====== TOP 3 LUẬT THEO LIFT — Khách hàng có nguy cơ rời bỏ ======
1. Khách mua [CHILDS GARDEN TROWEL PINK] thường mua kèm [CHILDS GARDEN FORK PINK]
   Support = 0.0107 | Confidence = 0.761 | Lift = 63.58
2. Khách mua [CHILDS GARDEN FORK PINK] thường mua kèm [CHILDS GARDEN TROWEL PINK]
   Support = 0.0107 | Confidence = 0.897 | Lift = 63.58
3. Khách mua [CHILDS GARDEN FORK PINK] thường mua kèm [CHILDS GARDEN FORK BLUE ]
   Support = 0.0101 | Confidence = 0.846 | Lift = 59.95
```

```
====== TOP 3 LUẬT THEO LIFT – Khách hàng trung thành ======
1. Khách mua [POPPY'S PLAYHOUSE LIVINGROOM ] thường mua kèm [POPPY'S PLAYHOUSE BEDROOM , POPPY'S PLAYHOUSE KITCHEN]
   Support = 0.0105 | Confidence = 0.727 | Lift = 51.50
2. Khách mua [POPPY'S PLAYHOUSE BEDROOM , POPPY'S PLAYHOUSE KITCHEN] thường mua kèm [POPPY'S PLAYHOUSE LIVINGROOM ]
   Support = 0.0105 | Confidence = 0.742 | Lift = 51.50
3. Khách mua [POPPY'S PLAYHOUSE LIVINGROOM , POPPY'S PLAYHOUSE KITCHEN] thường mua kèm [POPPY'S PLAYHOUSE BEDROOM ]
   Support = 0.0105 | Confidence = 0.837 | Lift = 48.74

Số luật xuất hiện ở cả 3 phân khúc: 79
  Khách VIP: 79/905 luật (8.7%) là luật chung
  Khách hàng có nguy cơ rời bỏ: 79/199 luật (39.7%) là luật chung
  Khách hàng trung thành: 79/196 luật (40.3%) là luật chung
```

4.2. Phân cụm khách hàng theo RFM.

4.2.1. Cơ sở lý thuyết.

- Mô hình RFM mô tả giá trị khách hàng qua ba chiều: mua gần đây đến đâu (Recency), mua thường xuyên đến đâu (Frequency) và chi bao nhiêu (Monetary).
- Phân cụm trên ba chỉ số này cho phép nhóm các khách có hành vi tương tự mà không cần nhãn trước.

4.2.2. So sánh phản biện K-Means và K-Medoids.

- ***K-Means*** tìm k tâm cụm để cực tiểu tổng bình phương khoảng cách từ mỗi điểm đến tâm của cụm chứa nó:

$$J = \Sigma(j = 1 \dots k)\ \Sigma\left(x \in C_j\right) | | x - \mu j | |^2 \qquad (5)$$

  Thuật toán lặp hai bước, gán điểm vào tâm gần nhất, cập nhật tâm bằng trung bình với độ phức tạp $O(n \cdot k \cdot d \cdot t)$ cho n điểm, k cụm, d chiều và t vòng lặp. Nhóm khởi tạo bằng K−Means++ và chạy 10 lần khởi tạo khác nhau (*n_init* = 10, *random_state* = 42). Nhược điểm là tâm cụm là điểm trung bình nên nhạy với ngoại lai và giả định cụm gần dạng cầu.
- ***K-Medoids (PAM)*** chọn tâm cụm là một điểm dữ liệu thật (*medoid*) và cực tiểu tổng khoảng cách tới medoid. Thuật toán gồm pha BUILD (chọn tham lam k medoid ban đầu) và pha SWAP (hoán đổi medoid với điểm khác nếu giảm được tổng chi phí). Mỗi vòng SWAP có độ phức tạp cỡ $O((k - n)^2)$ và cần ma trận khoảng cách $n \times n$. Ưu điểm là bền hơn với ngoại lai và mỗi tâm cụm là một khách hàng thật, giúp bộ phận marketing xem hồ sơ cụ thể.

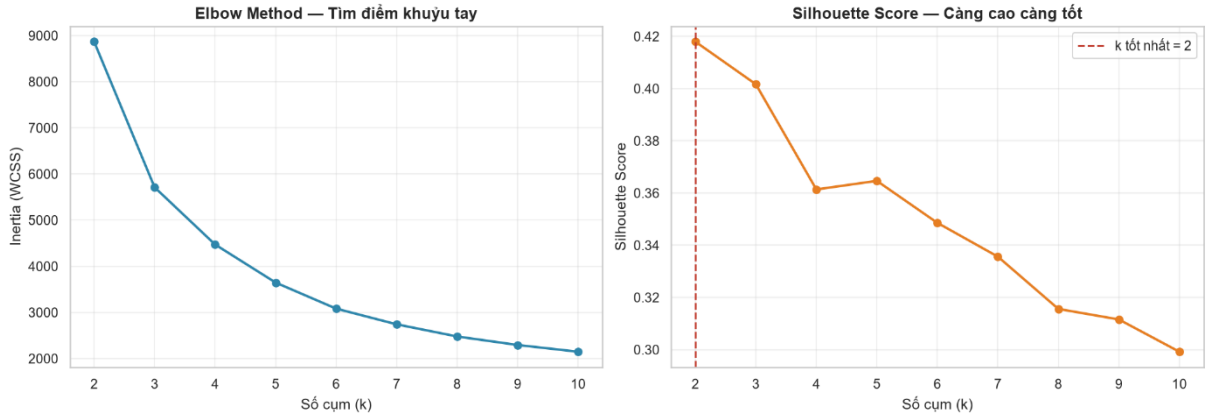
4.2.3. Chọn số cụm.

- Nhóm tính Inertia (cho phương pháp Elbow) và Silhouette với k từ 2 đến 10.
- Inertia giảm mạnh ở các giá trị k nhỏ rồi chậm dần, không có khuỷu tay rõ rệt.

- Silhouette cao nhất ở k = 2 (0.4180), nhưng chia khách chỉ thành hai nhóm thì quá thô để phân biệt khách VIP, khách phổ thông và khách đã nguội.
- Trong khoảng 3 đến 5 cụm, $k = 3$ có Silhouette cao nhất (0.4017, cao hơn $k = 4$ là 0.3614 và k = 5 là 0.3647), nên nhóm chọn $k = 3$.
- Đây là lựa chọn cân bằng giữa chất lượng cụm và khả năng diễn giải nghiệp vụ, và nhóm thừa nhận $k = 2$ có điểm Silhouette cao hơn.

Bảng 13. Inertia và Silhouette theo số cụm k.

k	Inertia	Silhouette
2	8,867.63	0.4180
3	5,710.00	0.4017
4	4,470.98	0.3614
5	3,646.28	0.3647
6	3,081.82	0.3486
7	2,741.67	0.3356
8	2,477.98	0.3156
9	2,293.72	0.3116
10	2,147.46	0.2992



Hình 8. Chọn số cụm k bằng Elbow và Silhouette.

4.2.4. Kết quả K-Means so với K-Medoids.

Bảng 14. So sánh K-Means và K-Medoids (PAM) với k = 3.

Chỉ tiêu	K-Means	K-Medoids (PAM)
Silhouette	0.4017	0.4012
Kích thước ba cụm	2,354 / 1,824 / 1,675	2,283 / 1,899 / 1,671
Hội tụ	Inertia 5,710.00	5 vòng SWAP; tổng chi phí 5,123.68
Tâm cụm	Điểm trung bình, không phải khách thật	Ba khách hàng thật (medoid)

```
Mức độ tương đồng giữa 2 thuật toán (Adjusted Rand Index - ARI): 0.9565
```

	Tiêu chí	K-Means	K-Medoids (PAM)
0	Silhouette Score	0.4017	0.4012
1	Kích thước các cụm	[2354, 1824, 1675]	[2283, 1899, 1671]
2	Loại tâm cụm	Centroid (Tâm cụm tính bằng trung bình)	Medoid (Một khách hàng thực tế)
3	Khả năng chịu ảnh hưởng của Outlier	Nhạy cảm hơn với Outlier	Ít nhạy cảm hơn với Outlier

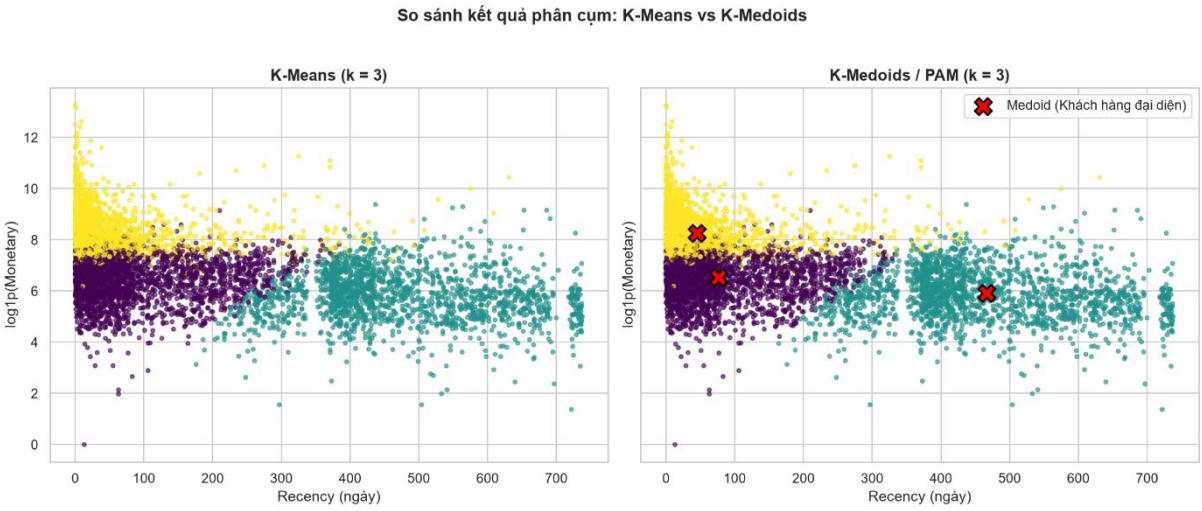
```
[Run K-Medoids PAM] Đã tính ma trận khoảng cách (5853, 5853) (~261 MB RAM).
[Run K-Medoids PAM] k = 3: hội tụ sau 5 vòng lặp, tổng chi phí = 5123.68, kích thước các cụm = [2283, 1899, 1671]

Chỉ số dòng của các khách hàng được chọn làm MEDOID: [2491, 5360, 1112]

Thông tin RFM của các khách hàng đại diện (MEDOID):
(Mỗi medoid là một khách hàng có thật trong dữ liệu, không phải điểm trung bình ảo như centroid của K-Means.)
```

	# Customer ID	# Recency	# Frequency	# Monetary
2491	14880.0	76	3	690.59
5360	17792.0	466	2	368.35
1112	13481.0	45	11	3830.84

- Hai thuật toán cho chất lượng gần như bằng nhau (Silhouette chênh 0.0005) và ARI = 0.9565 cho thấy cấu trúc phân khúc gần như trùng khớp.
- Ưu điểm của PAM là tâm cụm diễn giải được, nhưng chi phí tính toán và bộ nhớ cao hơn đáng kể.
- Vì vậy nhóm dùng K−Means làm kết quả chính (nhanh, ổn định, dễ lưu mô hình) và dùng PAM để xác nhận.
- Kết quả bootstrap cho thấy phân khúc ổn định, sau 30 lần lấy ngẫu nhiên 80% khách và phân cụm lại, ARI so với kết quả gốc trung bình 0.9808 ± 0.0120 (nhỏ nhất 0.9534; lớn nhất 0.9987).



Hình 9. So sánh kết quả K−Means và K−Medoids.

4.2.5. Hồ sơ các phân khúc.

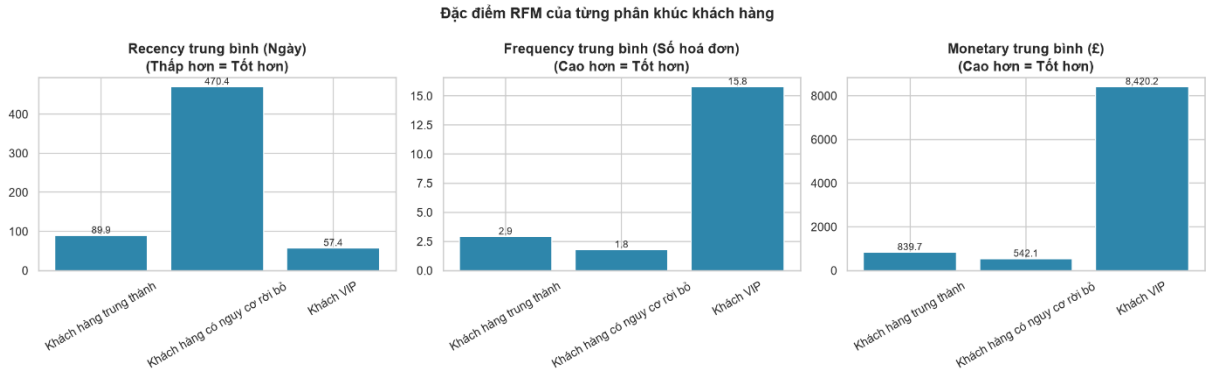
Bảng 15. Hồ sơ các phân khúc toàn kỳ (K−Means, k = 3).

Phân khúc	Số khách	% Khách	Recency TB (ngày)	Frequency TB	Monetary TB (£)	% Tổng Monetary
Khách VIP	1,675	28.62	57.39	15.80	8,420.25	82.6
Khách hàng trung thành	2,354	40.22	89.91	2.92	839.66	11.6
Khách hàng có nguy cơ rời bỏ	1,824	31.16	470.36	1.79	542.12	5.8

```
Cụm 0 – Khách hàng trung thành
   Số khách hàng : 2,354 (40.22%)
   Recency TB    : 90 ngày
   Frequency TB  : 2.9 hoá đơn
   Monetary TB   : £840

Cụm 1 – Khách hàng có nguy cơ rời bỏ
   Số khách hàng : 1,824 (31.16%)
   Recency TB    : 470 ngày
   Frequency TB  : 1.8 hoá đơn
   Monetary TB   : £542

Cụm 2 – Khách VIP
   Số khách hàng : 1,675 (28.62%)
   Recency TB    : 57 ngày
   Frequency TB  : 15.8 hoá đơn
   Monetary TB   : £8,420
```



Hình 10. Đặc điểm RFM trung bình của từng phân khúc.

- Nhóm VIP chiếm 28.62% số khách nhưng đóng góp khoảng 82.6% tổng giá trị chi tiêu, mua gần đây (57 ngày), mua nhiều (15.8 hoá đơn) và chi lớn (£8,420).
- Nhóm có nguy cơ rời bỏ mua lần cuối trung bình 470 ngày trước, chỉ 1.79 hoá đơn. Nhóm còn lại mua thỉnh thoảng (2.92 hoá đơn, £840).
- Lưu ý về tên gọi, tên phân khúc được gán tự động theo thứ hạng RFM của cụm. Nhóm "Khách hàng trung thành" thực chất chỉ là nhóm trung gian, mua trung bình khoảng ba lần; ở ***Mục 5.5*** sẽ thấy tới 62% trong số họ không quay lại, nên tên này chỉ có nghĩa tương đối so với hai nhóm còn lại.

4.3. Dự đoán khách hàng rời bỏ, ngừng mua (Churn).

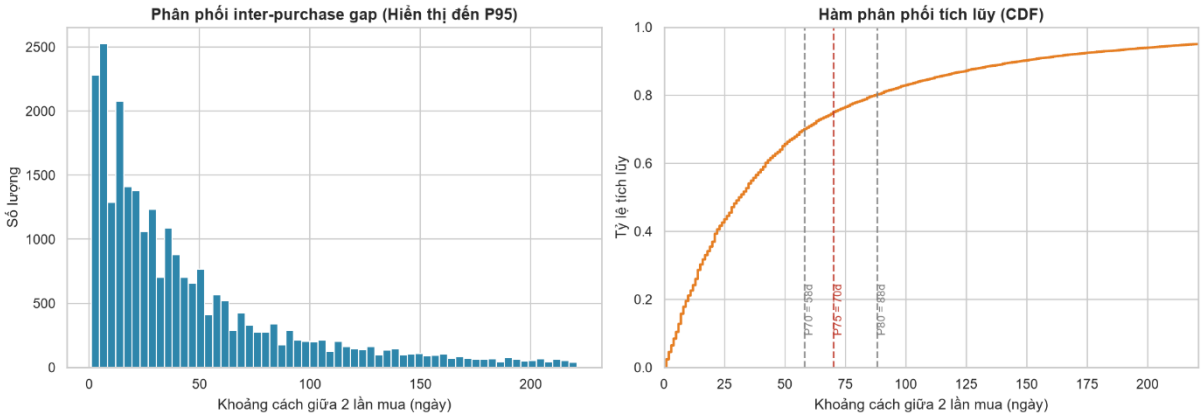
4.3.1. Định nghĩa nhãn Churn.

- Dữ liệu không có nhãn "Khách đã rời đi", nên nhóm định nghĩa Churn theo hành vi: tại *Snapshot s*, xét các khách đã có giao dịch đến hết *s*; khách được gán *Churn = 1* nếu không có giao dịch nào trong khoảng $(s,\ s+W)$, ngược lại *Churn = 0*. Đây chỉ là định nghĩa vận hành, không chứng minh khách đã rời doanh nghiệp vĩnh viễn.
- Độ dài cửa sổ W không được chọn tuỳ ý mà lấy từ phân phối khoảng cách giữa hai lần mua liên tiếp.
- Với toàn kỳ có 27,030 khoảng cách từ 4,179 khách mua lặp lại; 1,674 khách (28.6%) chỉ mua đúng một lần nên không có khoảng cách nào.
- Nhóm chọn phân vị 75 (P75) vì cân bằng: P50 = 32 ngày quá ngắn (sẽ gán Churn nhầm cho khách có chu kỳ mua dài), còn P90 = 148 ngày và P95 = 221 ngày quá dài (doanh nghiệp chỉ biết khách rời đi sau nhiều tháng, mất tính kịp thời).

	Percentile	# Gap (ngày)	Ý nghĩa
0	P50	32.0	50% Số lần mua liên tiếp cách nhau
1	P60	42.0	60% Số lần mua liên tiếp cách nhau
2	P70	58.0	70% Số lần mua liên tiếp cách nhau
3	P75	70.0	75% Số lần mua liên tiếp cách nhau
4	P80	88.0	80% Số lần mua liên tiếp cách nhau
5	P85	112.0	85% Số lần mua liên tiếp cách nhau
6	P90	148.0	90% Số lần mua liên tiếp cách nhau
7	P95	221.0	95% Số lần mua liên tiếp cách nhau

```
[Build Time Based Snapshots] Ngày cuối dữ liệu: 2011-12-09
  TRAIN: Snapshot = 2011-07-22, cửa sổ quan sát nhãn = (2011-07-22, 2011-09-30]
  TEST : Snapshot = 2011-09-30, cửa sổ quan sát nhãn = (2011-09-30, 2011-12-09]
[Build Time Based Snapshots] Ngày cuối dữ liệu: 2011-12-09
  TRAIN: Snapshot = 2011-07-22, cửa sổ quan sát nhãn = (2011-07-22, 2011-09-30]
  TEST : Snapshot = 2011-09-30, cửa sổ quan sát nhãn = (2011-09-30, 2011-12-09]
[Compute Inter Purchase Gaps] Đã lọc theo cutoff_date = 2011-07-22: còn 573,924/776,642 dòng giao dịch.
[Compute Inter Purchase Gaps] Thu được 19,884 khoảng cách từ 3,460 khách mua lặp lại.
[Compute Inter Purchase Gaps] Có 1,621 khách chỉ mua đúng 1 lần (31.9%)
[Suggest Churn Window] Cửa sổ Churn đề xuất theo P75: 67 ngày.
  ⇒ Khách hàng không quay lại mua trong 67 ngày được coi là đã rời bỏ, vì 75% các chu kỳ mua thực tế đều ngắn hơn khoảng này.

So sánh: P75 sơ bộ (toàn kỳ)   = 70 ngày
         P75 chính thức (Train) = 67 ngày
```



Hình 11. Phân phối khoảng cách giữa hai lần mua liên tiếp.

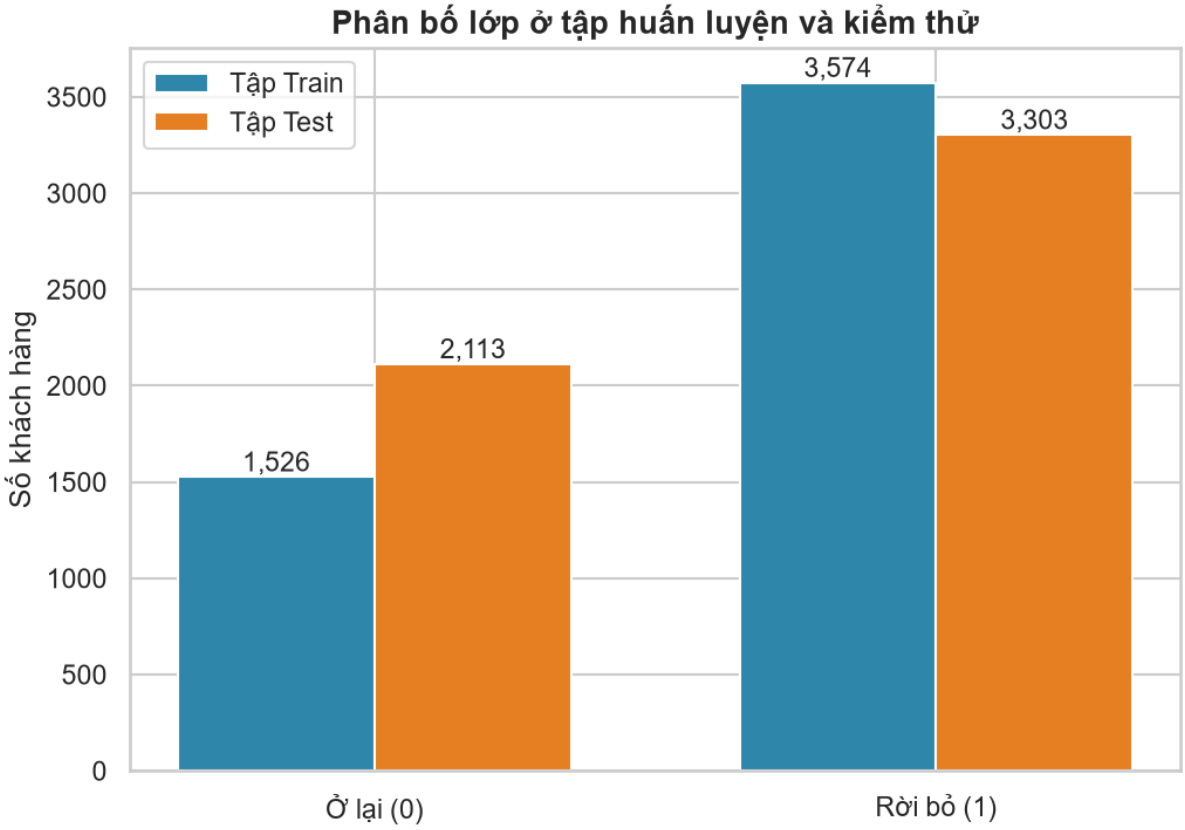
4.3.2. Tách tập Train/Test theo thời gian.

- Vì đặc trưng phụ thuộc thời gian, nhóm không chia ngẫu nhiên mà dùng hai Snapshot nối tiếp.
- Cửa sổ nhãn của Train kết thúc đúng tại Snapshot của Test, nên hai tập không chồng lấn.
- Một khách có thể có mặt ở cả hai tập với đặc trưng khác nhau; kết quả vì vậy đánh giá khả năng dự đoán cho quần thể khách đã có lịch sử, không phải cho khách hoàn toàn mới.

Bảng 16. Thiết kế tách tập Train/Test theo thời gian.

Tập	Snapshot	Cửa sổ nhãn	Số khách	Churn = 1	Tỷ lệ
Train	28/07/2011	(28/07/2011, 03/10/2011]	5,100	3,574	70.1%
Test	03/10/2011	(03/10/2011, 09/12/2011]	5,416	3,303	61.0%

```
Xây dựng tập TRAIN – Snapshot = 2011-07-28
------------------------------------------------------------------------
[Calculate RFM] Đã loại 0 dòng thiếu 'Customer ID' (Còn lại 776,642 dòng để tính RFM).
[Calculate RFM] Mốc Snapshot Date = 2011-07-28. Đã loại 198,191 dòng có ngày giao dịch Sau mốc này (Còn lại 578,451 dòng).
[Calculate RFM] Đã tính RFM cho 5,100 khách hàng.
[Add Churn Features] Đã bổ sung 3 đặc trưng: AvgOrderValue, Tenure, AvgGapDays cho 5,100 khách hàng.
[Generate Churn Labels] Snapshot = 2011-07-28, cửa sổ = 67 ngày -> 5,100 khách hàng, Churn = 3,574 (70.1%), không Churn = 1,526
→ Tập TRAIN: 5,100 khách hàng
→ Phân bố Churn: {0: 1526, 1: 3574}
Xây dựng tập TEST – Snapshot = 2011-10-03
------------------------------------------------------------------------
[Calculate RFM] Đã loại 0 dòng thiếu 'Customer ID' (Còn lại 776,642 dòng để tính RFM).
[Calculate RFM] Mốc Snapshot Date = 2011-10-03. Đã loại 127,133 dòng có ngày giao dịch Sau mốc này (Còn lại 649,509 dòng).
[Calculate RFM] Đã tính RFM cho 5,416 khách hàng.
[Add Churn Features] Đã bổ sung 3 đặc trưng: AvgOrderValue, Tenure, AvgGapDays cho 5,416 khách hàng.
[Generate Churn Labels] Snapshot = 2011-10-03, cửa sổ = 67 ngày -> 5,416 khách hàng, Churn = 3,303 (61.0%), không Churn = 2,113
→ Tập TEST: 5,416 khách hàng
→ Phân bố Churn: {0: 2113, 1: 3303}
```



Hình 12. Phân bố lớp Churn ở tập Train và Test.

- Churn là lớp đa số ở cả hai tập (70.1% và 61.0%), vì vậy chỉ riêng Accuracy sẽ gây hiểu lầm: mô hình luôn đoán "Churn" đã đạt Accuracy 0.6099 trên Test.

4.3.3. Xử lý mất cân bằng bằng SMOTE.

- Trên tập Train, lớp thiểu số (không Churn) chỉ có 1,526 khách so với 3,574 khách Churn.
- SMOTE sinh thêm mẫu nhân tạo cho lớp thiểu số bằng cách nội suy giữa một điểm và các láng giềng gần nhất cùng lớp.
- Sau SMOTE, Train có 7,148 mẫu (mỗi lớp 3,574; sinh thêm 2,048 mẫu). SMOTE chỉ được áp dụng trên Train; tập Test giữ nguyên phân bố thật.
- Một lưu ý kỹ thuật: SMOTE dùng khoảng cách Euclid trên đặc trưng chưa chuẩn hoá, nên đặc trưng có thang lớn như Monetary có thể chi phối việc chọn láng giềng.

```
[Apply Smote] Phân bố lớp trước Smote: {0: 1526, 1: 3574} (Tổng 5,100 mẫu)
[Apply Smote] Phân bố lớp sau Smote  : {0: 3574, 1: 3574} (Tổng 7,148 mẫu)
[Apply Smote] Đã sinh thêm 2,048 mẫu nhân tạo cho lớp thiểu số

Train trước SMOTE : 5,100 mẫu
Train sau SMOTE   : 7,148 mẫu
Test giữ nguyên    : 5,416 mẫu với tỷ lệ Churn 61.0%
```

4.3.4. So sánh phản biện ba thuật toán phân lớp.

- *Thuật toán Decision Tree:*
  - Nguyên lý: Chia đệ quy theo ngưỡng đặc trưng để giảm độ tạp Gini (CART).
  - Ưu điểm: Dễ giải thích; không cần chuẩn hoá; không nhạy với đặc trưng lệch.
  - Nhược điểm: Dễ quá khớp; kém ổn định khi dữ liệu thay đổi nhẹ.
  - Mức độ phù hợp: Phù hợp nếu giới hạn độ sâu; đặc trưng lệch không cần log
- *Thuật toán Random Forest:*
  - Nguyên lý: Tập hợp T cây trên mẫu bootstrap và tập đặc trưng ngẫu nhiên, bỏ phiếu.
  - Ưu điểm: Giảm phương sai; thường chính xác hơn cây đơn; cho độ quan trọng đặc trưng.
  - Nhược điểm: Khó giải thích hơn; mô hình lớn; xác suất theo tỷ lệ phiếu.
  - Mức độ phù hợp: Phù hợp để nắm quan hệ phi tuyến giữa sáu đặc trưng.

- *Thuật toán Gaussian Naive Bayes:*
  - Nguyên lý: Áp dụng định lý Bayes với giả định đặc trưng độc lập có điều kiện và phân phối chuẩn theo lớp.
  - Ưu điểm: Rất nhanh; ít tham số; ổn định; Recall cao.
  - Nhược điểm: Giả định độc lập bị vi phạm (Monetary, Frequency, AvgOrderValue tương quan); phân phối lệch; xác suất không hiệu chuẩn.
  - Mức độ phù hợp: Dùng làm mô hình nhanh; F1 cao chủ yếu nhờ Recall.

4.3.5. Tinh chỉnh siêu tham số.

- Nhóm tinh chỉnh *Decision Tree* và *Random Forest* bằng *GridSearchCV* với StratifiedKFold 5-fold (giữ tỷ lệ lớp ở mỗi fold) và thước đo F1.
- Naive Bayes không có tinh chỉnh siêu tham số cần chọn nên giữ cấu hình mặc định (***var_smoothing = 1e-9***).

```
[Tune Model] Đã tinh chỉnh 'decision_tree' bằng GridSearchCV (5-fold, scoring = f1).
[Tune Model] Bộ tham số tốt nhất: {'max_depth': 4, 'min_samples_leaf': 20}
[Tune Model] f1 trung bình tốt nhất (CV): 0.7588

[Tune Model] Đã tinh chỉnh 'random_forest' bằng GridSearchCV (5-fold, scoring = f1).
[Tune Model] Bộ tham số tốt nhất: {'max_depth': 15, 'min_samples_leaf': 5, 'n_estimators': 200}
[Tune Model] f1 trung bình tốt nhất (CV): 0.7881
```

- Kết quả tinh chỉnh trên tập Test (***Mục 5.1***) không đồng đều. Với Decision Tree, cây đơn giản hơn nhiều (16 lá thay vì 57) mà F1 tăng từ 0.7816 lên 0.7899 và AUC từ 0.7737 lên 0.7785, nghĩa là bản mặc định hơi quá khớp.
- Với *Random Forest*, cấu hình tốt nhất theo CV phức tạp hơn (depth 15, leaf 5) nhưng không cải thiện trên Test: F1 từ 0.7894 xuống 0.7876 và AUC từ 0.7825 xuống 0.7736. Nhóm ghi nhận kết quả này như một phát hiện, không loại bỏ.
- GridSearchCV được chạy trên tập Train đã qua SMOTE, với các fold chia ngẫu nhiên. Mẫu tổng hợp trong fold kiểm định có thể được nội suy từ điểm nằm ở fold huấn luyện, nên điểm CV có thể lạc quan (CV F1 của Random Forest là 0.7881 trong khi F1 trên Test là 0.7876).

CHƯƠNG 5: ĐÁNH GIÁ MÔ HÌNH VÀ PHÂN TÍCH KẾT QUẢ (EVALUATION).

5.1. Thước đo đánh giá và kết quả tổng hợp.

- Vì Churn là lớp đa số (61.0% ở tập Test), Accuracy không phù hợp làm thước đo duy nhất.
- Nhóm dùng bốn thước đo, tính trên lớp *Churn = 1* (TP, FP, FN lần lượt là số khách Churn được đoán đúng, số khách không Churn bị đoán nhầm là Churn, và số khách Churn bị bỏ sót):

$$Precision = TP / (TP + FP) \qquad Recall = TP / (TP + FN) \qquad (6)$$

$$F1 = 2 \cdot Precision \cdot Recall / (Precision + Recall) \qquad (7)$$

- AUC là diện tích dưới đường cong ROC, có thể hiểu là xác suất mô hình cho điểm cao hơn một khách Churn ngẫu nhiên so với một khách không Churn ngẫu nhiên; AUC = 0.5 ứng với đoán ngẫu nhiên. Về ý nghĩa nghiệp vụ, Recall là tỷ lệ khách sắp rời đi mà doanh nghiệp phát hiện được, còn Precision là tỷ lệ cảnh báo thực sự đúng, tức hiệu quả của ngân sách chăm sóc.
- Mô hình Baseline luôn đoán "Churn" có Precision bằng tỷ lệ Churn (0.6099), Recall = 1, nên F1 = 2 × 0.6099 / (1 + 0.6099) = 0.7577 và Accuracy = 0.6099. Một mô hình chỉ đáng giá nếu vượt rõ Baseline này.
- Việc chọn siêu tham số dùng kiểm định chéo 5-fold phân tầng trên Train (***Mục 4.3.5***); đánh giá cuối cùng dùng tập Test tách theo thời gian, hoàn toàn không tham gia huấn luyện hay tinh chỉnh.
- Bảng dưới trình bày kết quả của năm cấu hình (ba mô hình mặc định và hai mô hình đã tinh chỉnh) so với Baseline:

Bảng 17. Kết quả các mô hình Churn trên tập Test.

Mô hình	Precision	Recall	F1	AUC	Accuracy	F1 − Baseline
Baseline	0.6099	1.0000	0.7577	0.5000	0.6099	0
Naive Bayes	0.6988	0.9337	0.7994	0.7837	0.7142	+ 0.0417
Decision Tree (Tuned)	0.7614	0.8205	0.7899	0.7785	0.7338	+ 0.0322

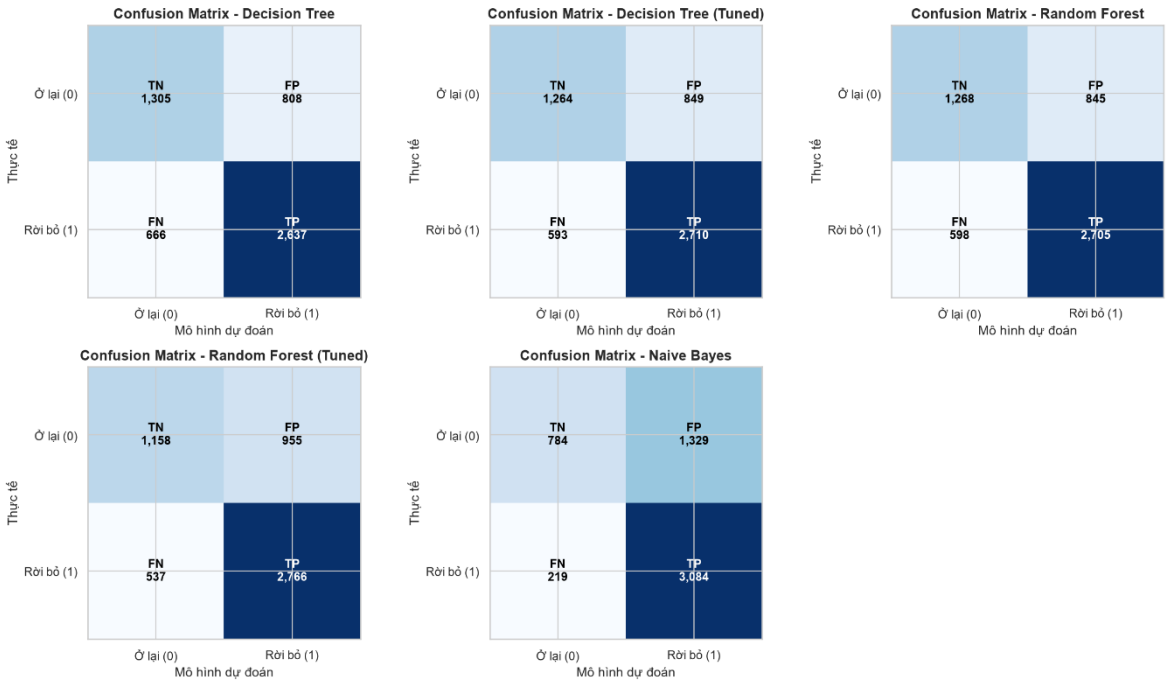
Random Forest	0.7620	0.8190	0.7894	0.7825	0.7336	+ 0.0317
Random Forest (Tuned)	0.7433	0.8374	0.7876	0.7736	0.7245	+ 0.0299
Decision Tree	0.7655	0.7984	0.7816	0.7737	0.7278	+ 0.0239

	Model name	# Precision	# Recall	# F1	# AUC	# Accuracy	# Baseline Accuracy	# Improvement over Baseline
0	Naive Bayes	0.6988	0.9337	0.7994	0.7837	0.7142	0.6099	0.1043
1	Decision Tree (Tuned)	0.7614	0.8205	0.7899	0.7785	0.7338	0.6099	0.1239
2	Random Forest	0.762	0.819	0.7894	0.7825	0.7336	0.6099	0.1237
3	Random Forest (Tuned)	0.7433	0.8374	0.7876	0.7736	0.7245	0.6099	0.1147
4	Decision Tree	0.7655	0.7984	0.7816	0.7737	0.7278	0.6099	0.118

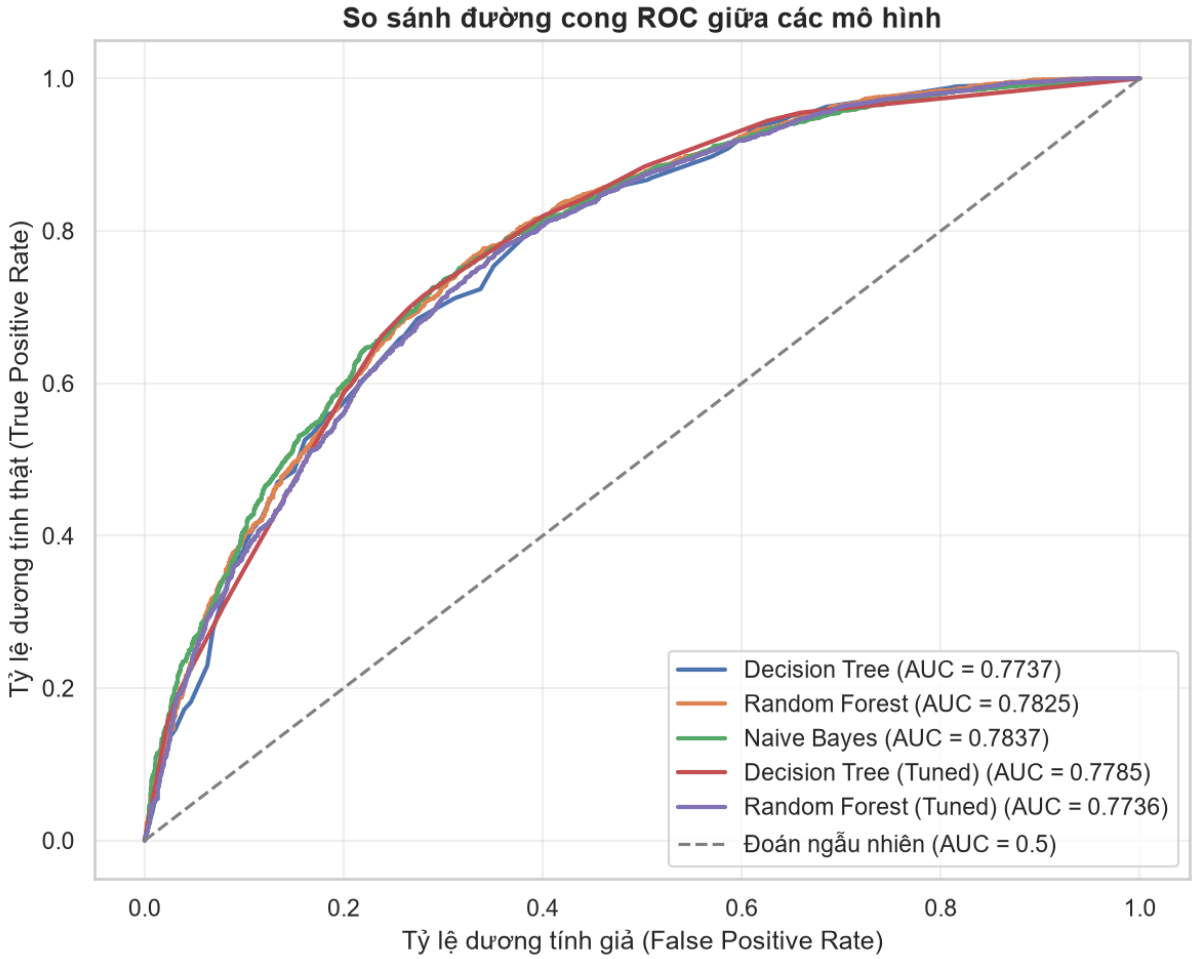
- Nếu chỉ nhìn Accuracy, cả ba mô hình mặc định đều vượt Baseline Accuracy từ 10.4% đến 12.4%, một mức tưởng như rất lớn. Nhưng khi đặt F1 cạnh Baseline F1 (0.7577), mức vượt chỉ còn từ 2.4% đến 4.2%.
- Phần lớn cải thiện của Accuracy đến từ việc tỷ lệ Churn cao, không phải từ năng lực phân biệt của mô hình; đây là lý do nhóm báo cáo thêm Baseline F1.

5.2. Phân tích kết quả mô hình Churn.

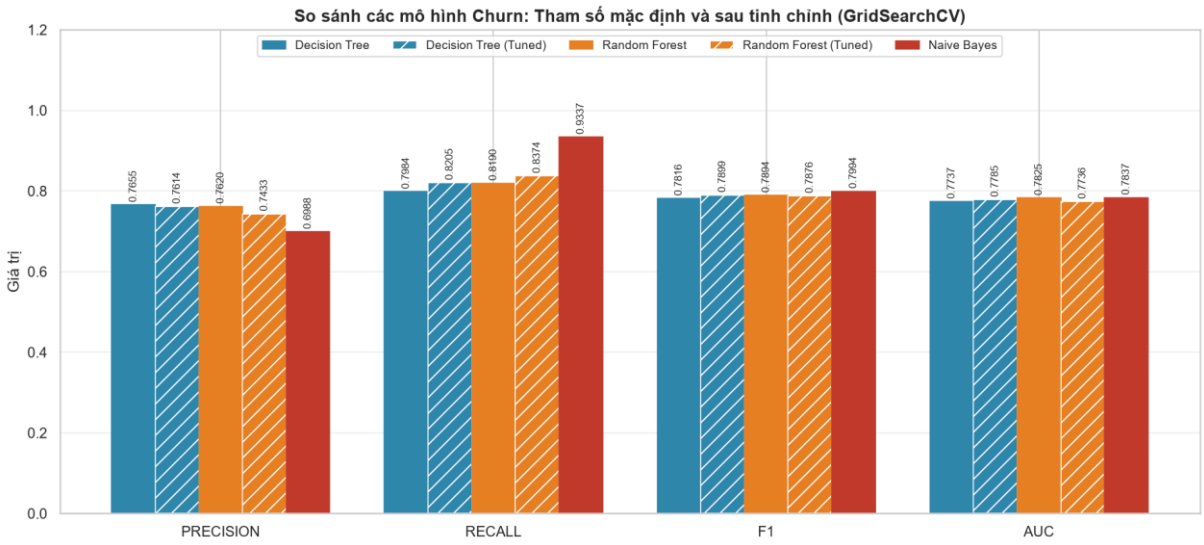
- Naive Bayes dẫn đầu F1 (0.7994) và AUC (0.7837), nhưng bằng cách đánh đổi Precision lấy Recall. Mô hình đạt Recall 0.9337, tức phát hiện hầu hết khách sẽ rời đi, đồng thời có Precision thấp nhất (0.6988), nghĩa là cảnh báo nhầm nhiều.
- Hai mô hình dựa trên cây cân bằng hơn (Precision khoảng 0.76, Recall khoảng 0.82).
- Việc chọn mô hình vì thế phụ thuộc chi phí nghiệp vụ, nếu bỏ sót một khách Churn đắt hơn nhiều so với một ưu đãi gửi nhầm, Naive Bayes phù hợp; nếu ngân sách chăm sóc hạn chế, Random Forest hoặc Decision Tree đã tinh chỉnh hiệu quả hơn.
- Chênh lệch giữa các mô hình nhỏ, F1 của bốn mô hình dẫn đầu nằm trong khoảng 0.7876 đến 0.7994 (chênh 0.012) và AUC từ 0.7736 đến 0.7837. Với 5,416 khách Test và không có kiểm định thống kê, nhóm không kết luận mô hình nào "thật sự" tốt hơn.
- Vì vậy báo cáo không dùng cụm từ "mô hình tốt nhất" một cách tuyệt đối.



Hình 13. Ma trận nhầm lẫn của ba mô hình trên tập Test.

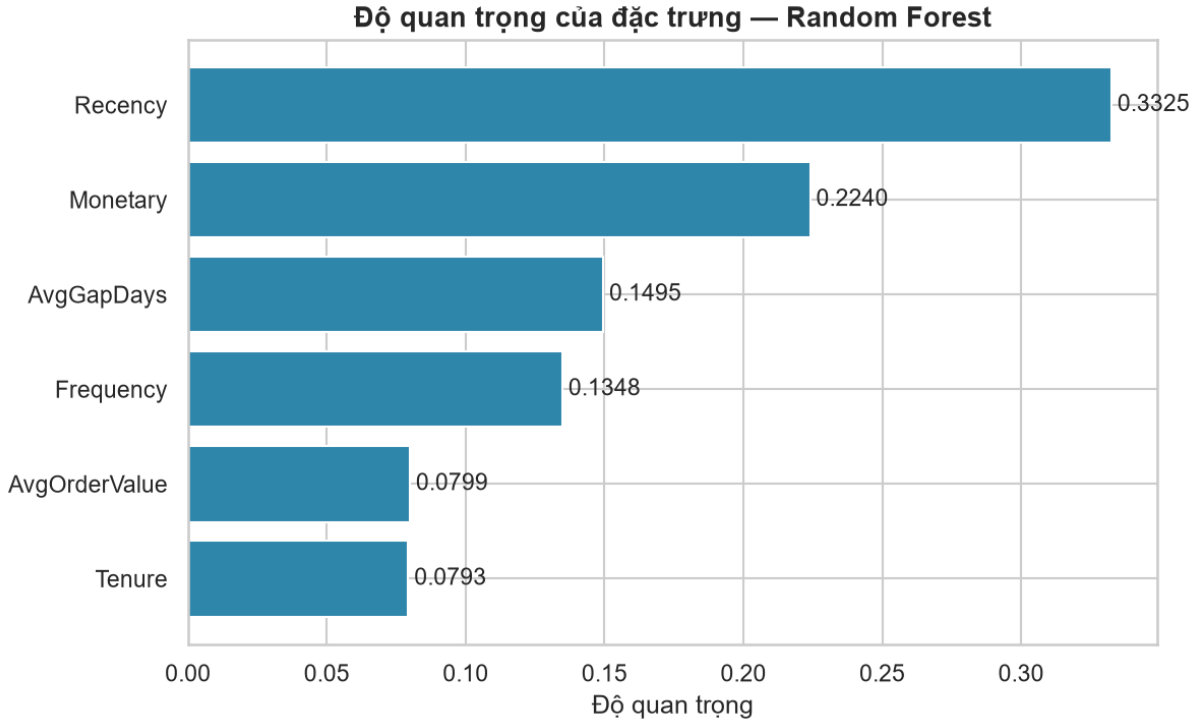


Hình 14. Đường cong ROC của các mô hình.



Hình 15. So sánh Precision, Recall, F1, AUC của các mô hình.

- Độ quan trọng đặc trưng: Với Random Forest mặc định, Recency là đặc trưng quan trọng nhất (khoảng 0.33), tiếp theo là Monetary (khoảng 0.23), AvgGapDays (0.15), Frequency (0.13), AvgOrderValue (0.08) và Tenure (0.08).
- Kết quả hợp lý về nghiệp vụ: Khách càng lâu không mua thì càng ít khả năng quay lại trong cửa sổ 67 ngày. Tuy nhiên nên hiểu đây là mối liên hệ dự đoán, không phải quan hệ nhân quả, và việc Recency chi phối cho thấy một phần sức dự đoán chỉ phản ánh khách đã rời bỏ từ lâu.



Hình 16. Độ quan trọng đặc trưng của Random Forest.

5.3. Đánh giá kết quả phân cụm.

- Chất lượng phân cụm được đánh giá trên ba khía cạnh. Về cấu trúc cụm, Silhouette của K−Means là 0.4017.
- Giá trị trong khoảng 0.26 đến 0.50 chỉ ra cấu trúc cụm yếu, các cụm chồng lấn một phần. Điều này hợp lý vì RFM là dữ liệu liên tục, không có ranh giới tự nhiên rõ ràng; phân khúc ở đây là một cách chia có ích cho nghiệp vụ hơn là các cụm tách biệt tự nhiên.
- Về tính tái lập, ARI bootstrap trung bình 0.9808 và ARI giữa K−Means và PAM là 0.9565 cho thấy kết quả chia ổn định dù ranh giới không tự nhiên. Về khả năng diễn giải, ba cụm có hồ sơ RFM khác biệt rõ và gọi tên được (***Mục 4.2.5***).

5.4. Đánh giá luật kết hợp.

- Với Support từ 0.02, các luật hàng đầu có Lift từ 13.78 đến 25.53 và Kulczynski từ 0.604 đến 0.745, các sản phẩm trong luật không chỉ đi cùng nhau nhiều hơn kỳ vọng (Lift) mà mối liên hệ còn đối xứng giữa hai chiều (Kulczynski).
- Ở ***Mục 4.1.6***, chỉ 8.7% luật của nhóm VIP là luật chung với hai phân khúc kia, cho thấy sản phẩm gợi ý nên được điều chỉnh theo từng nhóm khách, nhưng chênh lệch này cũng chịu ảnh hưởng mạnh của quy mô mẫu.
- Về ý nghĩa thực tiễn, các luật mạnh nhất là mua theo bộ sưu tập, cùng dòng sản phẩm, phù hợp để bán theo bộ hoặc xếp cạnh nhau; chúng chưa chứng minh một gợi ý sẽ làm tăng doanh thu, điều chỉ có thể kết luận bằng thử nghiệm A/B.

```
TOP 5 LUẬT KẾT HỢP CÓ LIFT CAO NHẤT (Support ≥ 0.02):

1. [PINK REGENCY TEACUP AND SAUCER] → [GREEN REGENCY TEACUP AND SAUCER]
   Support = 0.0209  |  Confidence = 0.837  |  Lift = 25.53  |  Kulczynski = 0.737

2. [GREEN REGENCY TEACUP AND SAUCER] → [ROSES REGENCY TEACUP AND SAUCER ]
   Support = 0.0250  |  Confidence = 0.763  |  Lift = 22.17  |  Kulczynski = 0.745

3. [ALARM CLOCK BAKELIKE RED ] → [ALARM CLOCK BAKELIKE GREEN]
   Support = 0.0202  |  Confidence = 0.613  |  Lift = 19.92  |  Kulczynski = 0.635

4. [DOLLY GIRL LUNCH BOX] → [SPACEBOY LUNCH BOX ]
   Support = 0.0200  |  Confidence = 0.621  |  Lift = 18.80  |  Kulczynski = 0.614

5. [CHARLOTTE BAG PINK POLKADOT] → [RED RETROSPOT CHARLOTTE BAG]
   Support = 0.0260  |  Confidence = 0.679  |  Lift = 13.78  |  Kulczynski = 0.604
```

5.5. Đối chiếu chéo phân khúc RFM với nguy cơ Churn.

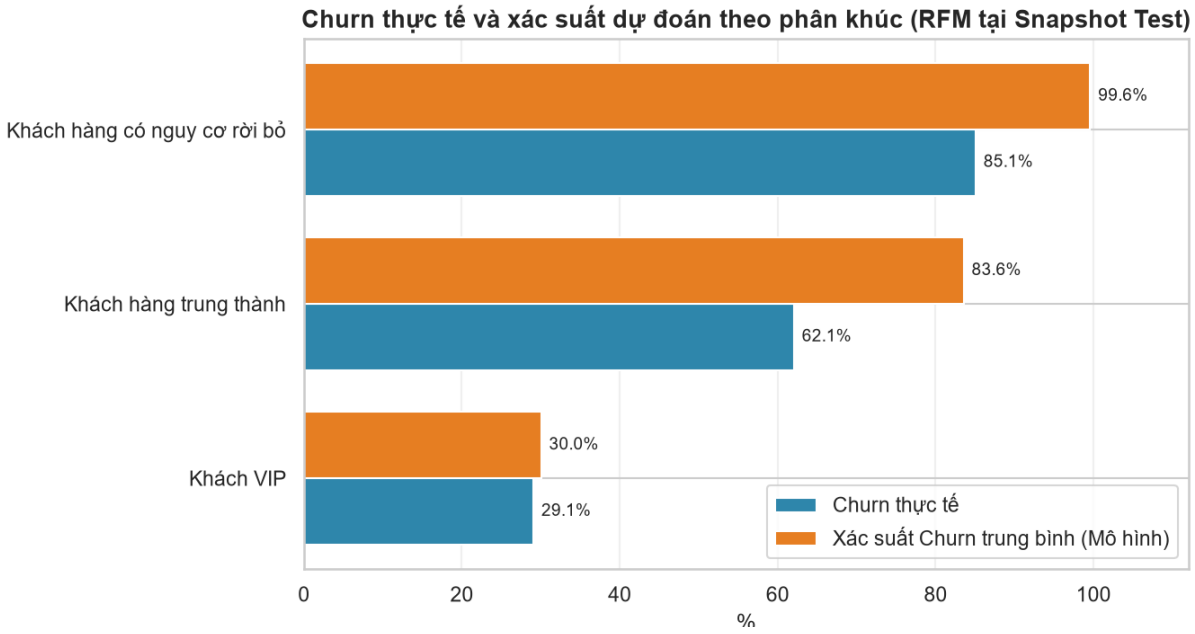
- Mục tiêu của phần này là xem các phân khúc có thật sự khác nhau về nguy cơ rời bỏ hay không, và mô hình Churn có nhất quán với phân khúc hay không.
- Nếu dùng phân khúc toàn kỳ (RFM tính đến 09/12/2011) để đối chiếu với nhãn Churn của tập Test (cửa sổ 03/10 đến 09/12/2011), phép so sánh bị vòng tròn: Recency toàn kỳ đã chứa thông tin của chính cửa sổ nhãn, vì khách mua trong cửa sổ đó có Recency nhỏ.
- Khi đó nhóm Recency cao gần như chắc chắn Churn = 1 do cách xây dựng và con số "100% Churn" không có giá trị kiểm chứng.
- Nhóm xử lý bằng cách tính lại RFM tại đúng Snapshot Test (03/10/2011) cho 5,416 khách, chạy lại K-Means với $k = 3$ và đặt tên theo cùng quy tắc. Phân khúc này không nhìn thấy cửa sổ nhãn nên đối chiếu là hợp lệ.

Bảng 18. Phân khúc RFM tính tại Snapshot Test (5,416 khách hàng).

Phân khúc	Số khách	% khách	Recency TB (ngày)	Frequency TB	Monetary TB (£)
Khách VIP	1,424	26.29	64.43	15.36	8,159.49
Khách hàng trung thành	2,204	40.69	122.06	3.01	910.28
Khách hàng có nguy cơ rời bỏ	1,788	33.01	419.78	1.57	449.86

Bảng 19. Đối chiếu Churn thực tế và dự đoán theo phân khúc.

Phân khúc	Churn thực tế	Xác suất Churn TB	Tỷ lệ dự đoán Churn	AUC trong phân khúc
Khách VIP	29.07%	30.04%	29.78%	0.6927
Khách hàng trung thành	62.07%	83.56%	99.86%	0.6394
Khách hàng có nguy cơ rời bỏ	85.07%	99.59%	100.00%	0.6222



Hình 17. Xác suất Churn dự đoán và tỷ lệ Churn thực tế theo phân khúc.

- Thứ tự rủi ro nhất quán: Cả Churn thực tế (29.1%, 62.1%, 85.1%) và xác suất Churn trung bình của mô hình (30.0%, 83.6%, 99.6%) đều tăng theo thứ tự: Khách VIP, Khách trung thành, Khách có nguy cơ. Khác với cách đối chiếu toàn kỳ, nhóm nguy cơ ở đây có 85.1% Churn thực tế, tức khoảng 15% (267 khách) vẫn quay lại trong cửa sổ 67 ngày.
- Hiệu chuẩn: Chỉ nhóm VIP có tỷ lệ dự đoán Churn (29.8%) sát thực tế (29.1%). Với nhóm trung thành, mô hình dự đoán 99.9% khách Churn trong khi thực tế là 62.1%, tương ứng khoảng 836 khách bị cảnh báo nhầm. Xác suất của Gaussian Naive Bayes thường không được hiệu chuẩn tốt, hay sát 0 hoặc 1, nên xác suất Churn trung bình chỉ nên đọc như điểm xếp hạng rủi ro.
- Giá trị bổ sung của mô hình: AUC của mô hình tính riêng trong từng phân khúc (0.6927, 0.6394, 0.6222) thấp hơn AUC chung (0.7837). Điều này cho thấy một phần sức phân biệt của mô hình đến từ khác biệt giữa các phân khúc (chủ yếu qua Recency); bên trong cùng một phân khúc, mô hình chỉ phân biệt ở mức vừa phải.
- Giới hạn của phép đối chiếu: RFM và mô hình Churn cùng dựa trên lịch sử mua trước Snapshot, nên sự nhất quán giữa chúng là kiểm tra nhất quán trên cùng một nguồn thông tin, không phải bằng chứng của hai phương pháp độc lập.

5.6. Ý nghĩa thực tiễn và đề xuất hành động.

- Từ các kết quả trên, nhóm em đề xuất hành động theo từng phân khúc như bảng:

Bảng 20. Hành động đề xuất theo phân khúc.

Phân khúc	Đặc điểm	Hành động đề xuất	Chỉ số theo dõi
Khách VIP	26.3% khách; Monetary TB £8,159; Churn thực tế 29.1%	Chương trình khách hàng thân thiết, chăm sóc cá nhân hoá; liên hệ trực tiếp khi mô hình báo rủi ro cao vì đây là khách giá trị lớn	Tỷ lệ giữ chân; giá trị đơn
Khách hàng trung thành	40.7% khách; Monetary TB £910; Churn thực tế 62.1%	Ưu đãi giữ chân ngay lần mua kế tiếp; khuyến khích tăng tần suất mua	Tỷ lệ quay lại trong 67 ngày
Khách hàng có nguy cơ rời bỏ	33.0% khách; Monetary TB £450; Churn thực tế 85.1%	Chiến dịch tái kích hoạt giá rẻ (Email, ưu đãi có thời hạn); không đầu tư lớn vì đa số khó quay lại	Tỷ lệ kích hoạt lại

CHƯƠNG 6: TRIỂN KHAI, TÁI LẬP VÀ SẢN PHẨM DEMO (DEPLOYMENT).

6.1. Kiến trúc mã nguồn.

- Mã nguồn được tổ chức theo nguyên tắc tách logic xử lý, thư mục Source dưới dạng module Python khỏi phần trình bày và chạy thực nghiệm thư mục Notebooks.

Bảng 21. Cấu trúc thư mục và module mã nguồn.

Thư mục / Tệp	Nội dung
Data/Raw	File dữ liệu gốc
Data/Processed	Transactions_Clean.csv, Customer_RFM.csv và các bảng trung gian sau làm sạch
Data/Interim	Kết quả của các mô hình: luật kết hợp, phân khúc, dự đoán Churn, bảng so sánh mô hình
Source/Preprocessing	Cleaning.py, Feature_Engineering.py
Source/Utils	IO.py đường dẫn đọc/ghi CSV ,Visualization.py vẽ biểu đồ
Source/RFM	RFM_Calculator.py (RFM theo Snapshot), Clustering.py (K-Means, PAM tự cài đặt, đặt tên phân khúc)
Source/MBA	Association_Rules.py (Ma trận one-hot, Apriori, FP-Growth, sinh luật, Kulczynski)
Source/Churn	Label_Generator.py (nhãn Churn, Snapshot, đặc trưng), Models.py (SMOTE, mô hình, GridSearchCV), Evaluation.py (thước đo, ROC, độ quan trọng đặc trưng)
Notebooks	01 đến 06: hiểu dữ liệu, chuẩn bị, luật kết hợp, phân cụm, Churn, tổng hợp và so sánh
Models	Các mô hình đã lưu (.pkl): Decision Tree, Random Forest, Naive Bayes, K-Means
Figures	Các biểu đồ sinh từ Notebooks, đánh số theo thứ tự xuất hiện
Demo	Ứng dụng Streamlit (Main.py, Common.py, các trang, Styles.css)

6.2. Tái lập kết quả.

- Để chạy lại từ đầu, người dùng cài môi trường theo ***requirements.txt*** rồi chạy tuần tự sáu Notebook:
  - Tạo môi trường ảo và cài thư viện: ***pip install -r requirements.txt***.
  - Đặt file dữ liệu ***online_retail_II.xlsx*** vào thư mục ***Data/Raw***.
  - Chạy lần lượt Notebook 01 đến 06 (Restart & Run All cho từng Notebook). Mỗi Notebook ghi kết quả vào Data/Processed, Data/Interim, Models và Figures để Notebook sau đọc.
  - Chạy ứng dụng Demo: ***streamlit run Demo/Main.py*** từ thư mục gốc.
- Các kiểm tra nhất quán đã cài đặt: Apriori và FP-Growth phải cho cùng số *itemsets* (nếu không, Notebook báo lỗi); các Notebook kiểm tra số khách giữa các bảng (5,853 khách ở RFM và phân khúc); Notebook 06 nạp lại toàn bộ mô hình đã lưu để xác nhận file đọc được; ứng dụng Demo kiểm tra bộ phân khúc dựng lại có khớp kết quả đã lưu hay không (hiển thị ở trang Phân khúc RFM).

6.3. Ứng dụng Demo Streamlit..

- Để có thể dùng kết quả của bài tập nhanh chóng, nhóm xây dựng ứng dụng Demo bằng Streamlit gồm sáu trang.
- Ứng dụng chỉ đọc kết quả đã sinh ra, không chạy lại quy trình huấn luyện, nên khởi động nhanh và gọn nhẹ.

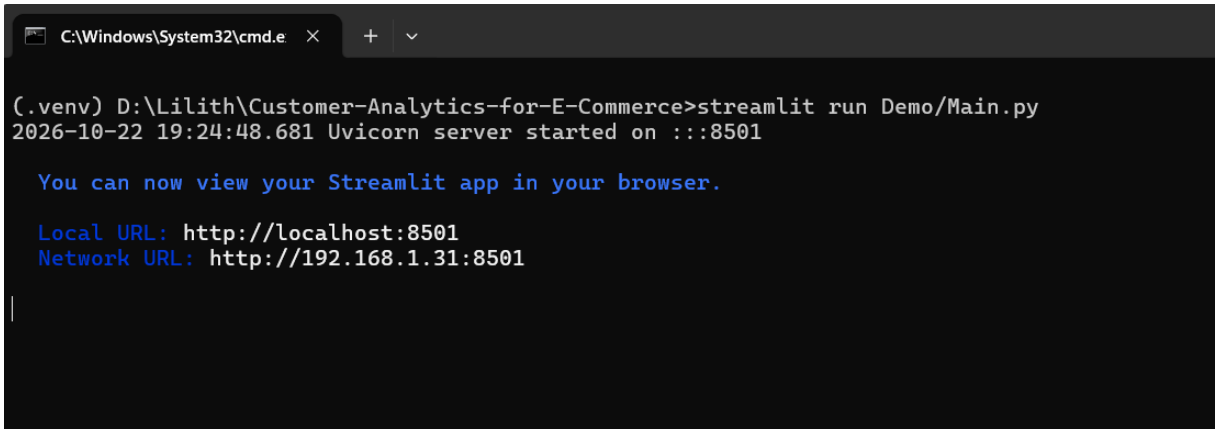
Bảng 22. Các trang của ứng dụng Demo.

Trang	Chức năng	Giá trị nghiệp vụ
Tổng quan	Chỉ số chính, ba góc nhìn, đóng góp theo phân khúc, F1 so với Baseline	Cái nhìn nhanh cho quản lý
Phân khúc RFM	Hồ sơ từng phân khúc, phân bố RFM, biểu đồ phân tán; kiểm tra đồng bộ mô hình K-Means	Hiểu giá trị các nhóm khách
Dự đoán Churn	Tra cứu khách trong tập Test, nhập khách mới (kịch bản mẫu), danh sách khách cần chăm sóc ưu tiên có tải CSV	Xác định ai cần can thiệp trước

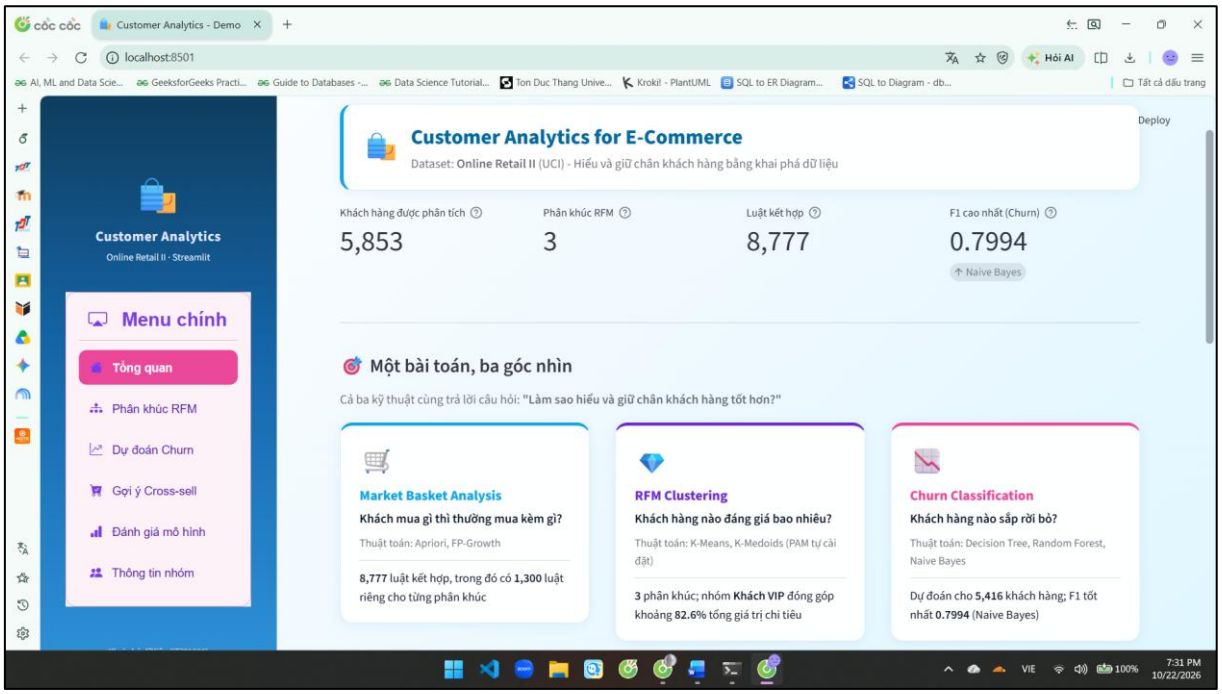
Gợi ý Cross-sell	Luật theo phân khúc, theo sản phẩm, tổng quan luật	Gợi ý bán kèm
Đánh giá mô hình	So sánh mô hình, ROC và ma trận nhầm lẫn theo ngưỡng kéo thả, phương pháp và hạn chế	Minh bạch về chất lượng mô hình
Về nhóm	Thông tin dự án, Notebook, thành viên	–

- Một số điểm kỹ thuật đáng chú ý:
  - Thứ nhất, tệp ***KMeans_RFM.pkl*** chỉ chứa mô hình K-Means mà không kèm bộ chuẩn hoá, nên ứng dụng dựng lại StandardScaler từ chính dữ liệu RFM đã dùng huấn luyện rồi kiểm tra độ khớp với nhãn đã lưu.
  - Thứ hai, đường ROC và ma trận nhầm lẫn ở trang Đánh giá được tính trực tiếp bằng cách chạy các mô hình ***.pkl*** trên tập Test, nên AUC phải khớp với bảng kết quả của Notebook 05.
  - Thứ ba, do xác suất của Naive Bayes thường sát 0 hoặc 1, ứng dụng hiển thị mức rủi ro kèm cảnh báo hiệu chuẩn và cho phép đổi mô hình để so sánh.
- Nhân viên chăm sóc khách hàng mở trang Dự đoán Churn, nhập thông số của một khách (hoặc chọn kịch bản mẫu), nhận phân khúc, mức rủi ro, hành động đề xuất và ba luật bán kèm của phân khúc đó; hoặc mở tab danh sách ưu tiên để lấy các khách rủi ro cao có giá trị chi tiêu lớn nhất và tải về dưới dạng CSV.

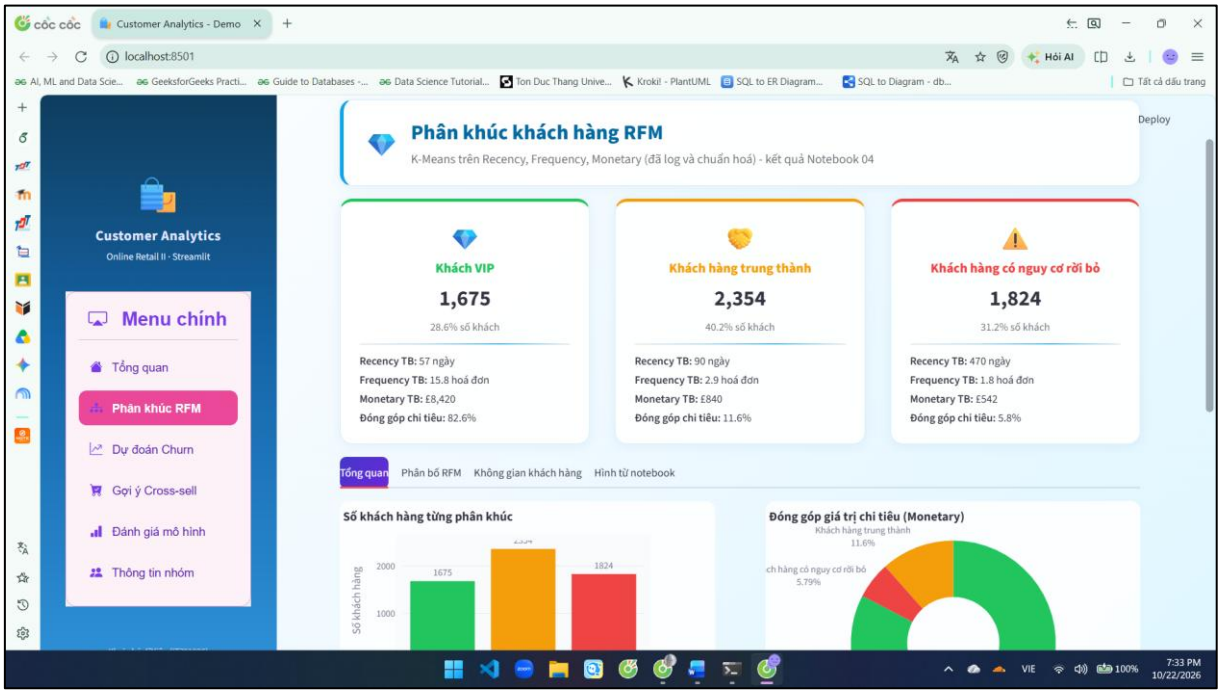
6.4. Kết quả Demo.



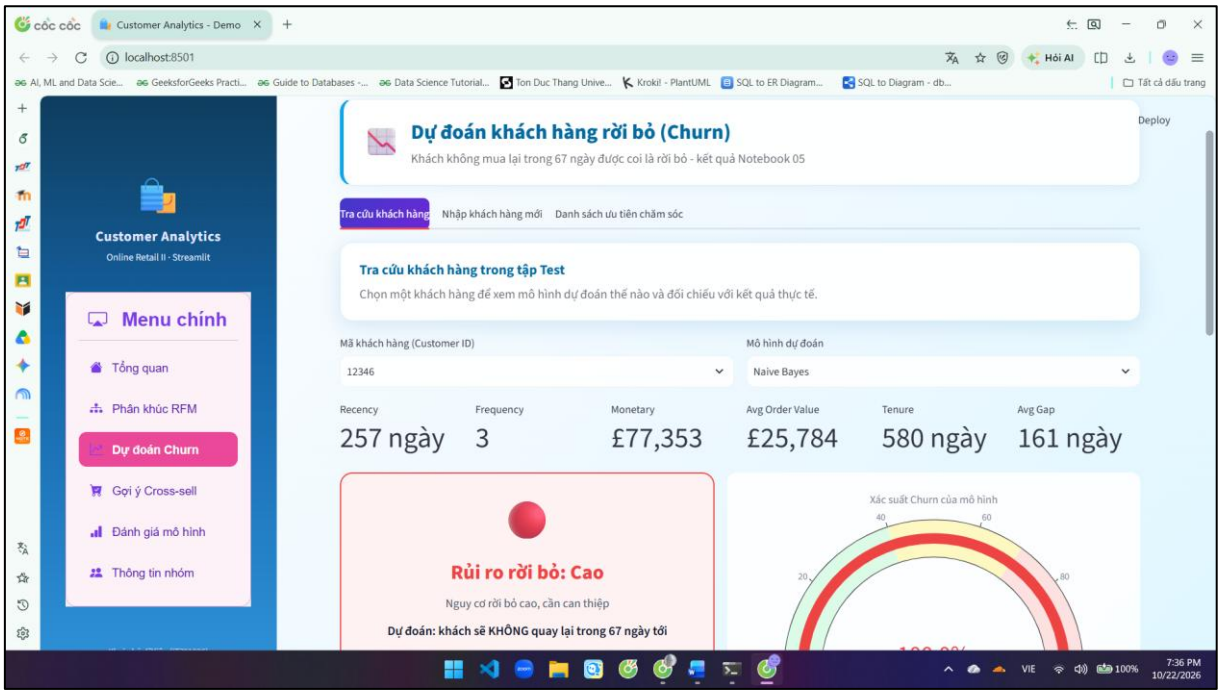
Hình 18. Khởi động dự án.



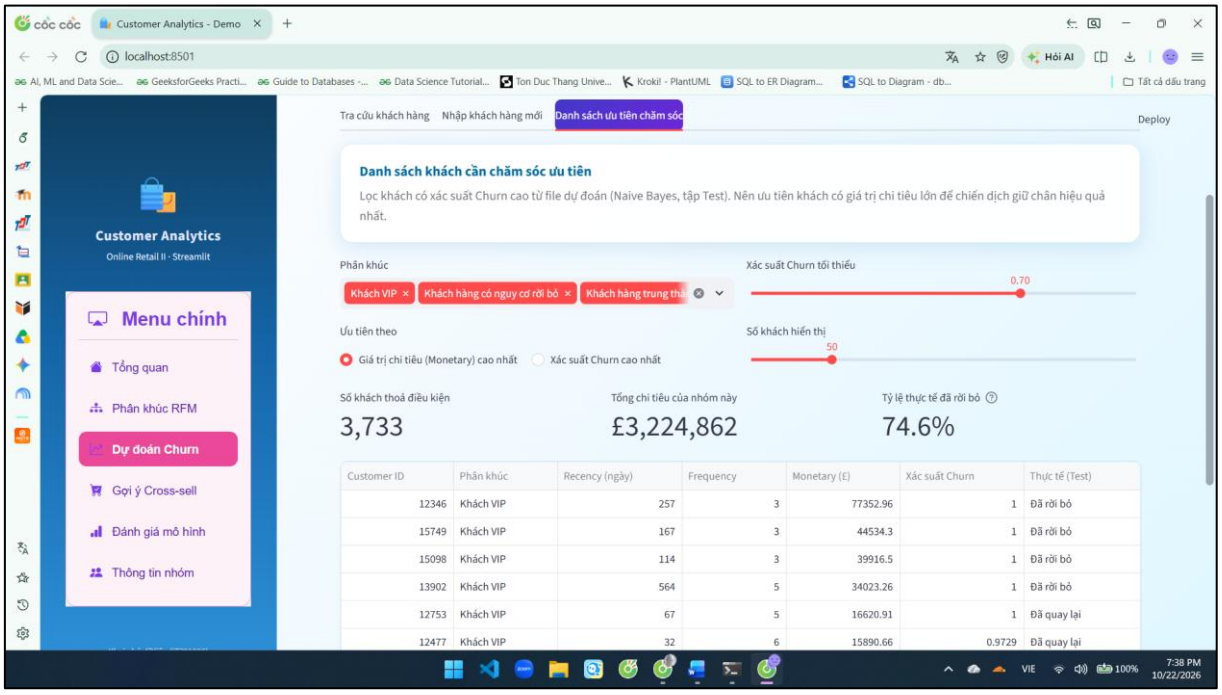
Hình 19. Demo trang Tổng quan.



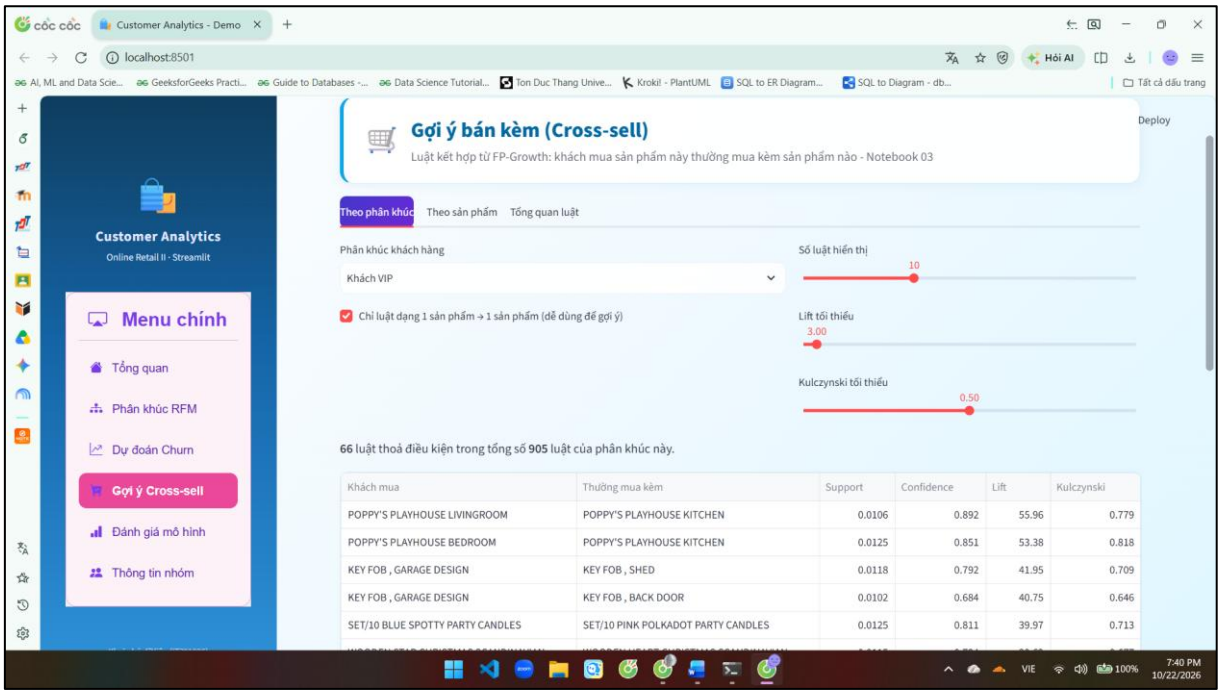
Hình 20. Demo trang Phân khúc RFM.



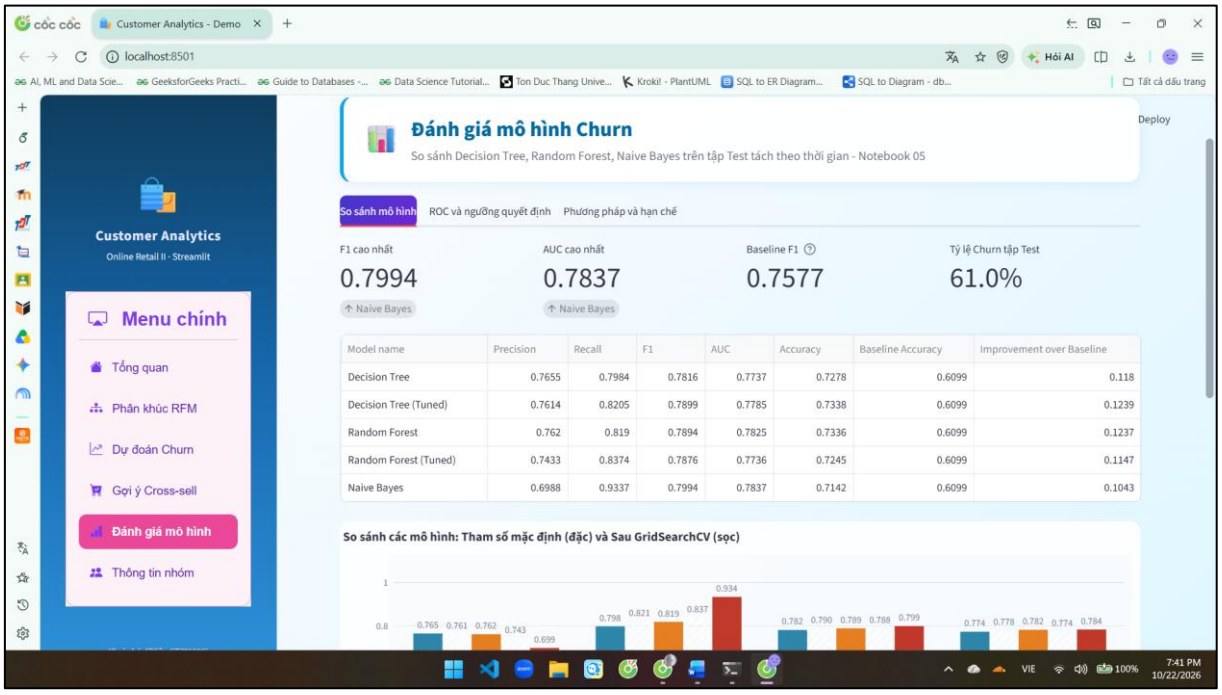
Hình 21. Demo trang Dự đoán Churn.



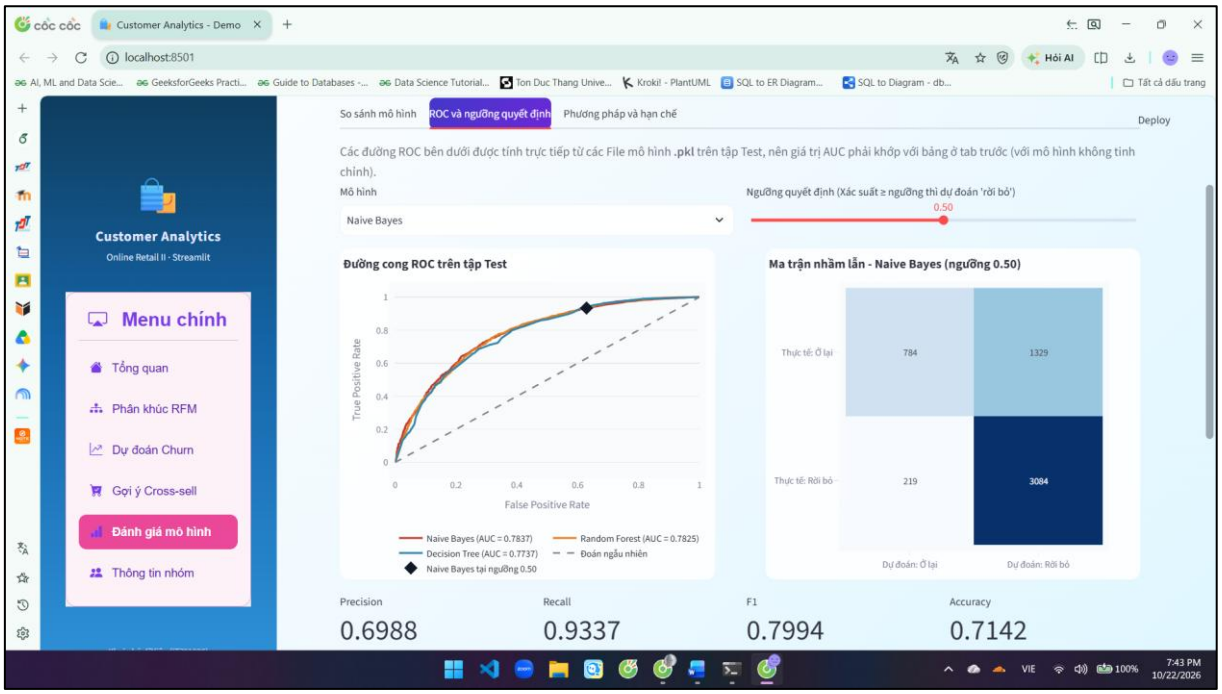
Hình 22. Demo danh sách khách hàng cần chăm sóc ưu tiên.



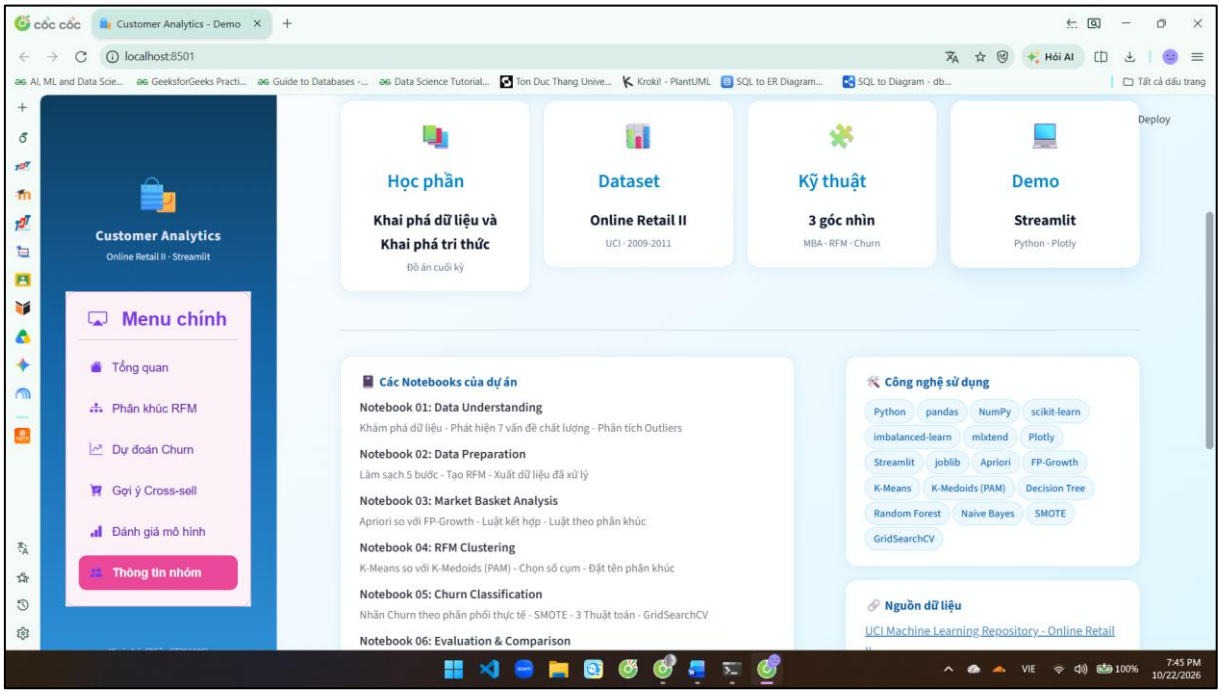
Hình 23. Demo trang gợi ý Cross-sell.



Hình 24. Demo trang Đánh giá mô hình.



Hình 25. Demo trang ROC và ngưỡng quyết định.



Hình 26. Demo trang Thông tin nhóm.

CHƯƠNG 7: TỔNG KẾT, TỰ ĐÁNH GIÁ VÀ PHÂN CÔNG CÔNG VIỆC.

7.1. Tổng kết.

Bảng 23. Tổng kết kết quả so với mục tiêu ban đầu.

Tiêu chí	Kết quả
Tái lập quy trình	Sáu Notebooks chạy tuần tự, đường dẫn tương đối; có kiểm tra nhất quán giữa các bước
Churn vượt Baseline	F1 0.7994 so với Baseline 0.7577 (+0.0417); AUC 0.7837 so với 0.5; Test tách theo thời gian
Phân khúc ổn định, diễn giải được	Ba phân khúc; ARI bootstrap 0.9808; ARI K-Means và PAM 0.9565; Silhouette 0.4017
Luật kết hợp có ý nghĩa	8,777 luật; luật hàng đầu có Lift 13.78 đến 25.53 ở Support từ 0.02; có luật theo phân khúc
Sản phẩm minh hoạ	Ứng dụng Streamlit sáu trang đọc kết quả từ CSV và mô hình ***.pkl***

7.2. Đóng gói của dự án.

- Một quy trình thống nhất cho ba kỹ thuật (luật kết hợp, phân cụm, phân lớp) trên cùng nguồn dữ liệu đã làm sạch, có biện minh số liệu cho từng bước làm sạch.
- Thiết kế bài toán Churn chống rò rỉ dữ liệu, tách Train/Test theo thời gian, ngưỡng cửa sổ chỉ tính từ dữ liệu trước Snapshot Train, SMOTE chỉ trên Train.
- So sánh thuật toán dựa trên đo đạc trực tiếp, kể cả khi kết quả khác kỳ vọng (FP−Growth không nhanh hơn ở mọi ngưỡng; tinh chỉnh không cải thiện Random Forest).
- Phát hiện và sửa lỗi vòng tròn trong đối chiếu phân khúc với Churn; bổ sung Baseline F1 và AUC trong từng phân khúc để đánh giá trung thực mức cải thiện của mô hình.
- Kết nối ba kỹ thuật ở mức phân khúc, luật bán kèm riêng cho từng nhóm khách và hành động đề xuất theo rủi ro.
- Ứng dụng Demo cho phép người không chuyên tra cứu, nhập khách mới và lấy danh sách ưu tiên.

7.3. Hạn chế.

- Tinh chỉnh siêu tham số chưa tách SMOTE khỏi vòng kiểm định chéo. Việc tinh chỉnh được thực hiện trên tập Train đã SMOTE với fold ngẫu nhiên, nên điểm CV có thể lạc quan và tham số chọn được có thể chưa tối ưu. Đánh giá cuối cùng thực hiện trên tập Test tách theo thời gian và không bị ảnh hưởng. Hướng cải tiến: đặt SMOTE trong Pipeline của CV.
- Mô hình xuất dự đoán được chọn theo F1 trên chính tập Test, nên bảng dự đoán dùng cho phân tích chéo và Demo chỉ mang tính minh hoạ, không phải ước lượng độc lập về mô hình tốt nhất.
- Các mô hình dẫn đầu chênh nhau rất ít và chưa được kiểm định thống kê; mức vượt Baseline F1 chỉ khoảng 2.4 đến 4.2 điểm phần trăm.
- Xác suất của Naive Bayes không được hiệu chuẩn, chỉ nên dùng để xếp hạng rủi ro; AUC trong từng phân khúc (0.62 đến 0.69) thấp hơn AUC chung.
- SMOTE áp dụng trên đặc trưng chưa chuẩn hoá, nên các đặc trưng có thang lớn như Monetary có thể chi phối việc chọn láng giềng; chưa có thí nghiệm so sánh với chuẩn hoá trước SMOTE.
- Định nghĩa Churn, cửa sổ 67 ngày dùng chung cho mọi khách; khách chỉ mua một lần (28.6% số khách toàn kỳ) không có khoảng cách nào nên không đóng góp vào ngưỡng; nhãn Test kết thúc đúng ngày cuối của dữ liệu; nhiều khách "nguội" từ rất lâu nên dễ đoán (Recency chi phối).
- Hoá đơn huỷ chưa được đối trừ ngược với đơn gốc. Monetary và Frequency có thể bị thổi phồng ở một số khách (ví dụ khách 12346 có Monetary £77,352.96 chủ yếu từ một đơn 74,215 đơn vị).
- 22.77% dòng thiếu Customer ID, luật kết hợp dùng mọi hoá đơn còn RFM và Churn chỉ dùng khách có định danh, nên các kết quả mô tả hai tập khác nhau; luật theo phân khúc loại 11.6% hoá đơn.
- Dữ liệu một doanh nghiệp tại Anh (91.94% số dòng), trong hai năm; tính mùa vụ (cao điểm cuối năm) chưa được đưa vào mô hình.
- Luật kết hợp chỉ thể hiện sự đồng xuất hiện; Lift cao ở Support thấp kém tin cậy; luật các phân khúc nhỏ ít ổn định hơn do ngưỡng tuyệt đối thấp.
- Dòng trùng hoàn toàn bị loại (33,788 dòng) có thể gồm một số dòng hợp lệ.

7.4. Hướng phát triển.

- Đặt SMOTE trong Pipeline của kiểm định chéo, thử ***class_weight*** và chuẩn hoá trước SMOTE; chọn mô hình bằng tập validation theo thời gian thay vì Test.
- Hiệu chuẩn xác suất (*Platt scaling* hoặc *isotonic*) và chọn ngưỡng quyết định theo chi phí cảnh báo nhầm so với chi phí bỏ sót.
- Cửa sổ Churn cá nhân hoá theo AvgGapDays của từng khách; bài toán riêng cho khách chỉ mua một lần.
- Kiểm định thống kê (bootstrap) cho chênh lệch giữa các mô hình; thêm thước đo cho phân cụm (Davies–Bouldin, Calinski–Harabasz).
- Đối trừ hoá đơn huỷ với đơn gốc để tính doanh thu thuần; thêm đặc trưng mùa vụ và đặc trưng sản phẩm (danh mục đã mua) vào mô hình Churn.
- Thử nghiệm A/B các hành động đề xuất theo phân khúc để đo hiệu quả thực.

7.5. Phân công công việc.

- Nhóm gồm ba thành viên thực hiện theo quy trình CRISP-DM.
- Bảng dưới đây tóm tắt phân công công việc của từng thành viên trong nhóm:

MSSV	Họ và tên	Công việc phụ trách	% Đóng góp	Thang điểm (1−5)
52400199	Trần Văn Khang	- Notebook 01 và 02. - Module Preprocessing và Utils. - Data and Infrastructure Lead, hạ tầng dữ liệu, hiểu dữ liệu, làm sạch dữ liệu. - Thuyết trình giữa kỳ, viết báo cáo.	100%	5
52400055	Trần Tấn Lực	- Notebook 03 và 04. - Module MBA và RFM. - Pattern Mining Lead, luật kết hợp và phân cụm RFM. - Hỗ trợ làm Slide thuyết trình.	95%	4
52400192	Ngô Đức Huân	- Notebook 05 và 06. - Module Churn, tổng hợp và đối chiếu. - Hỗ trợ làm Slide thuyết trình.	95%	4

TÀI LIỆU THAM KHẢO

[1] Chen, D. (2019). *Online Retail II*. UCI Machine Learning Repository.

[2] Agrawal, R., & Srikant, R. (1994). Fast algorithms for mining association rules (Apriori).

[3] Han, J., Pei, J., & Yin, Y. (2000). Mining frequent patterns without candidate generation (FP-Growth).

[4] Chawla, N. V., et al. (2002). SMOTE.

[5] Rousseeuw, P. J. (1987). Silhouettes, cơ sở của chỉ số Silhouette.

[6] Kaufman, L., & Rousseeuw, P. J. (1990). *Finding Groups in Data*, K-Medoids/PAM.

[7] Breiman, L. (2001). Random Forests.

[8] Wu, T., Chen, Y., & Han, J. (2010). Re-examination of interestingness measures in pattern mining.

[9] Pedregosa, F., et al. (2011). Scikit-learn.

[10] Raschka, S. (2018). MLxtend.

[11] Han, J., Kamber, M., & Pei, J. (2012). *Data Mining: Concepts and Techniques* (3rd ed.).